

# 기계학습에 필요한 선형 대수

# *Contents*

---

I. 벡터/행렬

II. 고유값과 고유벡터

III. 스펙트럼 분해/특이값 분해

Scalar

Vector

Matrix

Tensor

1

$\begin{bmatrix} 1 \\ 2 \end{bmatrix}$

$\begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}$

$\begin{bmatrix} \begin{bmatrix} 1 & 2 \end{bmatrix} & \begin{bmatrix} 3 & 2 \end{bmatrix} \\ \begin{bmatrix} 1 & 7 \end{bmatrix} & \begin{bmatrix} 5 & 4 \end{bmatrix} \end{bmatrix}$

$a$



$\underline{a}, \vec{a}, \boldsymbol{a}, \mathbf{a}$

$\boldsymbol{A}, \mathbf{A}, \mathbf{A}$


벡터  
(vector)

# 벡터

- 벡터는 크기와 방향을 가진다.




서로 같은 벡터라 함은 '크기'와 '방향'이 둘다 같은 벡터임을 의미합니다.



# 벡터

## ■ IRIS Data

	Sepal.Length ▾	Sepal.Width ▾	Petal.Length ▾	Petal.Width ▾	Species ▾
1	5.1	3.5	1.4	0.2	setosa
2	4.9	3.0	1.4	0.2	setosa
3	4.7	3.2	1.3	0.2	setosa
4	4.6	3.1	1.5	0.2	setosa
5	5.0	3.6	1.4	0.2	setosa
6	5.4	3.9	1.7	0.4	setosa
7	4.6	3.4	1.4	0.3	setosa
8	5.0	3.4	1.5	0.2	setosa
9	4.4	2.9	1.4	0.2	setosa
10	4.9	3.1	1.5	0.1	setosa
11	5.4	3.7	1.5	0.2	setosa



**Iris Versicolor**



**Iris Setosa**



**Iris Virginica**

출처: 기계학습, 오일석 지음, 한빛아카데미 (2017)

# 벡터

## ■ 벡터

- 샘플을 특징 벡터로 feature vector 표현
- 예) Iris 데이터에서 꽃받침의 길이, 꽃받침의 너비, 꽃잎의 길이, 꽃잎의 너비라는 4개의 특징이 각각 5.1, 3.5, 1.4, 0.2인 샘플.  $\mathbf{x} \in \mathbf{R}^4$ .

$$\mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{pmatrix} = \begin{pmatrix} 5.1 \\ 3.5 \\ 1.4 \\ 0.2 \end{pmatrix}$$

- 여러 개의 특징 벡터를 첨자로 구분

$$\mathbf{x}_1 = \begin{pmatrix} 5.1 \\ 3.5 \\ 1.4 \\ 0.2 \end{pmatrix}, \mathbf{x}_2 = \begin{pmatrix} 4.9 \\ 3.0 \\ 1.4 \\ 0.2 \end{pmatrix}, \mathbf{x}_3 = \begin{pmatrix} 4.7 \\ 3.2 \\ 1.3 \\ 0.2 \end{pmatrix}, \dots, \mathbf{x}_{150} = \begin{pmatrix} 5.9 \\ 3.0 \\ 5.1 \\ 1.8 \end{pmatrix}$$

# 행렬

## ■ 행렬

- 여러 개의 벡터를 담음
- 훈련집합을 담은 행렬을 설계행렬(design matrix)이라 부름
- 예) Iris 데이터에 있는 150개의 샘플을 설계 행렬  $\mathbf{X}$ 로 표현

$$\mathbf{X} = \begin{pmatrix} 5.1 & 3.5 & 1.4 & 0.2 \\ 4.9 & 3.0 & 1.4 & 0.2 \\ 4.7 & 3.2 & 1.3 & 0.2 \\ 4.6 & 3.1 & 1.5 & 0.2 \\ \vdots & \vdots & \vdots & \vdots \\ 6.2 & 3.4 & 5.4 & 2.3 \\ 5.9 & 3.0 & 5.1 & 1.8 \end{pmatrix} = \begin{pmatrix} x_{1,1} & x_{1,2} & x_{1,3} & x_{1,4} \\ x_{2,1} & x_{2,2} & x_{2,3} & x_{2,4} \\ x_{3,1} & x_{3,2} & x_{3,3} & x_{3,4} \\ x_{4,1} & x_{4,2} & x_{4,3} & x_{4,4} \\ \vdots & \vdots & \vdots & \vdots \\ x_{149,1} & x_{149,2} & x_{149,3} & x_{149,4} \\ x_{150,1} & x_{150,2} & x_{150,3} & x_{150,4} \end{pmatrix}$$

← 행 row

↑  
열 column



# 텐서 (tensor)

## ■ 텐서(tensor)

- 3차원 이상의 구조를 가진 숫자 배열
- 예) 3차원 구조의 RGB 컬러 영상: 2차원 행렬이 세 장 있음
- 모든 차원을 포괄하는 표현.
- 스칼라는 0차원 텐서, 벡터는 1차원 텐서, 행렬은 2차원 텐서
- 6\*6\*3의 텐서 **A**

$$\mathbf{A} = \begin{pmatrix} 4 & 1 & 0 & 3 & 2 & 2 \\ 2 & 0 & 2 & 2 & 3 & 1 \\ 3 & 0 & 1 & 2 & 6 & 7 \\ 3 & 1 & 2 & 3 & 5 & 6 \\ 1 & 2 & 2 & 2 & 2 & 3 \\ 3 & 0 & 0 & 1 & 1 & 0 \\ 5 & 4 & 1 & 3 & 3 & 3 \\ 2 & 2 & 1 & 2 & 2 & 1 \end{pmatrix} \begin{pmatrix} 6 \\ 3 \\ 0 \\ 3 \\ 1 \end{pmatrix}$$

# 벡터의 곱

## ▷ 두 벡터의 곱

$$\mathbf{a} = (a_1, a_2, \dots, a_n)', \quad \mathbf{b} = (b_1, b_2, \dots, b_n)'$$

$$\mathbf{a} \text{와 } \mathbf{b} \text{의 곱} : \quad \mathbf{a}'\mathbf{b} = \mathbf{b}'\mathbf{a} = \sum_{k=1}^n a_k b_k : (= \mathbf{a} \cdot \mathbf{b})$$

$\mathbf{a} \cdot \mathbf{b}$ 로도 표현하고 **내적**(inner product or dot product)이라 부르기도 한다.

$$\text{eg.} \quad \mathbf{a}'\mathbf{a} = \sum a_i^2 = \|\mathbf{a}\|^2 \geq 0$$

:  $\|\cdot\|$ 는 벡터의 크기를 나타낸다(놈, norm).

위의 식에서 등호가 성립하는 경우는  $\mathbf{a} = \mathbf{0}$ 인 경우뿐이다.

## ※참고

$$\mathbf{u} = \begin{pmatrix} u_1 \\ u_2 \\ \vdots \\ u_n \end{pmatrix} : n \times 1 \text{ 열벡터} \Rightarrow$$

$$\mathbf{u}\mathbf{u}' = \begin{pmatrix} u_1^2 & u_1 u_2 & \cdots & u_1 u_n \\ u_2 u_1 & u_2^2 & \cdots & u_2 u_n \\ \vdots & \vdots & \ddots & \vdots \\ u_n u_1 & u_n u_2 & \cdots & u_n^2 \end{pmatrix} : n \times n \text{ 행렬},$$

$$\mathbf{u}'\mathbf{u} = \sum_{i=1}^n u_i^2 : 1 \times 1 \text{ 스칼라}$$

# 벡터의 크기

## ■ 벡터의 크기를 놈(norm)으로 측정

- 벡터의  $p$ 차 놈

$$p\text{차 놈: } \|\mathbf{x}\|_p = \left( \sum_{i=1,d} |x_i|^p \right)^{\frac{1}{p}} \quad (2.3)$$

$$\text{최대 놈: } \|\mathbf{x}\|_\infty = \max(|x_1|, |x_2|, \dots, |x_d|) \quad (2.4)$$

- 예)  $\mathbf{x} = (3 \ -4 \ 1)$  일 때, 2차 놈은  $\|\mathbf{x}\|_2 = (3^2 + (-4)^2 + 1^2)^{1/2} = 5.099$
- 2차놈: 유클리디언 놈(Euclidean norm)

- 단위벡터(unit vector): 길이가 1인 벡터 :  $\frac{\mathbf{x}}{\|\mathbf{x}\|_2}$

예)  $\mathbf{x} = \begin{pmatrix} 2 \\ 1 \end{pmatrix}$  이면,  $\|\mathbf{x}\|_2 = \sqrt{2^2 + 1^2} = \sqrt{5}$  이므로 길이가 1인 단위벡터(정규화된 벡터)

$$\text{는 } \mathbf{e} = \frac{1}{\sqrt{5}} \begin{pmatrix} 2 \\ 1 \end{pmatrix} = \begin{pmatrix} 2/\sqrt{5} \\ 1/\sqrt{5} \end{pmatrix} = \begin{pmatrix} 0.8944 \\ 0.4472 \end{pmatrix} \text{ 이다.}$$

# 행렬의 크기

- 행렬의 놈: 프로베니우스 놈 (Frobenius norm): 요소들의 제곱합의 제곱근

$$\text{프로베니우스 놈: } \|\mathbf{A}\|_F = \left( \sum_{i=1,n} \sum_{j=1,m} a_{ij}^2 \right)^{\frac{1}{2}} \quad (2.6)$$

$$\text{예를 들어, } \left\| \begin{pmatrix} 2 & 1 \\ 6 & 4 \end{pmatrix} \right\|_F = \sqrt{2^2 + 1^2 + 6^2 + 4^2} = 7.550$$

# 벡터의 선형독립

벡터공간  $\mathbf{X}$  에 속한 원소  $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n \in \mathbf{X}$  의 선형결합(linear combination)은

$$c_1\mathbf{x}_1 + c_2\mathbf{x}_2 + \dots + c_n\mathbf{x}_n = \mathbf{c}^T \mathbf{X}$$

라고 표현 가능하다. 영벡터가 아닌  $\mathbf{c} = (c_1, c_2, \dots, c_n)^T$  에 대해 선형결합이 0이 될 때,  $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$  는 선형종속이라고 하며, 오직  $\mathbf{c} = \mathbf{0}$  일 때만 선형결합이 0이 된다면, 이를 선형독립이라고 한다.

- $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n \in \mathbf{X}$  에 대하여,

$$c_1\mathbf{x}_1 + c_2\mathbf{x}_2 + \dots + c_n\mathbf{x}_n = \mathbf{c}^T \mathbf{X} = \mathbf{0}$$

을 만족하는  $\mathbf{c}$  가 오직  $\mathbf{c} = (c_1 \ c_2 \ \dots \ c_n)^T = (0 \ 0 \ \dots \ 0)^T$  일 때,  $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$  는 선형독립(linearly independent)이라고 하고,  $\mathbf{c} \neq \mathbf{0}$  일 때 이를 선형종속(linearly dependent)이라고 한다.

# 벡터의 선형독립

Example: 아래의 벡터는 서로 선형 독립이다.

$$\mathbf{x}_1 = \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix}, \quad \mathbf{x}_2 = \begin{pmatrix} 0 \\ 1 \\ -1 \end{pmatrix}, \quad \mathbf{x}_3 = \begin{pmatrix} 1 \\ -2 \\ 1 \end{pmatrix}$$

왜냐하면,

$$c_1\mathbf{x}_1 + c_2\mathbf{x}_2 + c_3\mathbf{x}_3 = \begin{pmatrix} c_3 \\ c_2 - 2c_3 \\ c_1 - c_2 + c_3 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}$$

에서

$$\mathbf{c} = (c_1 \ c_2 \ c_3)^T = (0 \ 0 \ 0)^T$$

일 수 밖에 없기 때문이다.

# 벡터의 선형종속

선형종속의 개념을 자세히 살펴보면,

- 만일 식

$$c_1\mathbf{x}_1 + c_2\mathbf{x}_2 + \cdots + c_n\mathbf{x}_n = \mathbf{c}^T\mathbf{X} = \mathbf{0}$$

의  $c_1, c_2, \dots, c_n$  중 적어도 한 개가 0 이 아니라고 가정하자.(  $i$ 번째 계수인  $c_i$  가 0 이 아니라고 하자). 이 때,

$$\mathbf{x}_i = -\frac{c_1}{c_i}\mathbf{x}_1 - \frac{c_2}{c_i}\mathbf{x}_2 - \cdots - \frac{c_{i-1}}{c_i}\mathbf{x}_{i-1} - \frac{c_{i+1}}{c_i}\mathbf{x}_{i+1} - \cdots - \frac{c_n}{c_i}\mathbf{x}_n$$

라고 표현 가능하게 되어서 결국  $\mathbf{x}_i$  가 나머지 원소들의 선형결합으로 표현되는 '종속관계'를 의미하게 된다.

# 벡터의 선형독립

◎ 예제 5.5 on p.150

$$\mathbf{x}_1 = \begin{pmatrix} 1 \\ 2 \\ -2 \end{pmatrix}, \quad \mathbf{x}_2 = \begin{pmatrix} -1 \\ 0 \\ 3 \end{pmatrix}, \quad \mathbf{x}_3 = \begin{pmatrix} 1 \\ 4 \\ -1 \end{pmatrix}$$

(1)  $2\mathbf{x}_1 + \mathbf{x}_2 - \mathbf{x}_3 = \mathbf{0} \Rightarrow \{\mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_3\} : \text{선형종속}$

(2)  $\alpha_1\mathbf{x}_1 + \alpha_2\mathbf{x}_2 = \mathbf{0}$ 이기 위해서는

$$\alpha_1 - \alpha_2 = 0, \quad 2\alpha_1 = 0, \quad -2\alpha_1 + \alpha_3 = 0 \Rightarrow \alpha_1 = \alpha_2 = 0 \text{ 이어야 하므로}$$
$$\Rightarrow \{\mathbf{x}_1, \mathbf{x}_2\} : \text{선형독립}$$

마찬가지로  $\{\mathbf{x}_1, \mathbf{x}_3\}, \{\mathbf{x}_2, \mathbf{x}_3\} : \text{선형독립}$

◎ # 5.5 on p.193

$$(1) \mathbf{x}_1 = \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix}, \quad \mathbf{x}_2 = \begin{pmatrix} 2 \\ 1 \\ 0 \end{pmatrix}, \quad \mathbf{x}_3 = \begin{pmatrix} 6 \\ 6 \\ 6 \end{pmatrix} \quad (2) \mathbf{x}_1 = \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix}, \quad \mathbf{x}_2 = \begin{pmatrix} 2 \\ 1 \\ 3 \end{pmatrix}, \quad \mathbf{x}_3 = \begin{pmatrix} 6 \\ 6 \\ 5 \end{pmatrix}$$



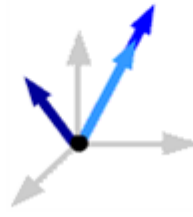
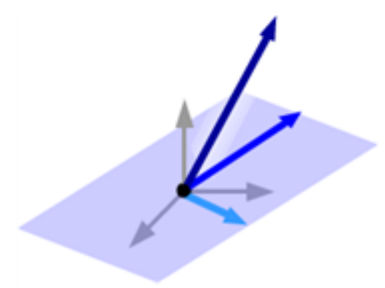
(1)  $\mathbf{x}_3 = 2\mathbf{x}_1 + 2\mathbf{x}_2$ 이므로  $\mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_3$ 는 선형종속이다.



(2) 선형연립방정식  $\alpha_1\mathbf{x}_1 + \alpha_2\mathbf{x}_2 + \alpha_3\mathbf{x}_3 = \mathbf{0}$ 을 풀면  $\alpha_1 = \alpha_2 = \alpha_3 = 0$

$$\Rightarrow \mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_3 : \text{선형독립}$$



# 벡터의 선형독립

	선형 종속	선형 독립
2차원		
3차원		



참고: 선형독립인 벡터의 수가 rank임.

선형독립인 벡터들은 기저(basis)를 이루지만 반드시 직교하는 것은 아님.

벡터공간을 구성하는 기본 요소인 기저(basis)가 직교정규벡터일 때 이를 직교정규기저(orthonormal basis)라고 함.

# 선형결합과 벡터공간

## ■ 벡터

- 공간상의 한 점으로 화살표 끝이 벡터의 좌표에 해당


## ■ 선형결합이 만드는 벡터공간(vector space)

- 기저벡터(basis vector) **a**와 **b**의 선형결합

$$\mathbf{c} = \alpha_1 \mathbf{a} + \alpha_2 \mathbf{b}$$


(2.12)

- $\alpha_1$ 과  $\alpha_2$ 를 변화시키면서 두 벡터 **a**와 **b**의 선형결합으로 만들어지는 공간을 **벡터공간**이라 부름




(a) 벡터에 스칼라 곱

그림 2-6 벡터의 연산




(b) 두 벡터의 덧셈



(a) 기저 벡터와 벡터공간

그림 2-7 벡터공간




(b) 정규직교 기저 벡터

정규직교 (orthonormal) 기저벡터: 길이가 1이고, 서로 수직인 기저벡터

출처: 기계학습, 오일석 지음, 한빛아카데미 (2017)

# 행렬의 계수(rank)

- 행렬의 계수: 선형독립인 열(행)벡터의 수



# 행렬의 계수(rank)

- 행렬  $\mathbf{A}$  의 계수(rank) :  
행 또는 열의 선형 독립인 벡터의 개수  
0 이 아닌 행 또는 열의 숫자

예)

$$A = \begin{bmatrix} 2 & 4 & 1 & 3 \\ -1 & -2 & 1 & 0 \\ 0 & 0 & 2 & 2 \\ 3 & 6 & 2 & 5 \end{bmatrix}$$

첫 번째 열과 세 번째 열은 선형독립이지만, 두 번째 열은 첫 번째 열의 두 배와 같고 네 번째 열은 첫 번째 열과 세 번째 열의 합과 같으므로  $\mathbf{A}$  의 계수는 2이다.  
가우스 소거법을 통해 다음과 같이 나타낼 수 있다.


$$A = \begin{bmatrix} 1 & 2 & 0 & 1 \\ 0 & 0 & 1 & 1 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix}$$

0이 아닌 행이 두 개임 => 계수가 2임.


# 벡터의 유사도

## ■ 유사도


- 벡터를 기하학적으로 해석



(a) 2차원 벡터



(b) 3차원 벡터



(c) 4차원 벡터(Iris 데이터)

그림 2-2 벡터를 기하학적으로 해석

- 두 벡터의 유사도 측정을 위해서 두 벡터의 내적을 사용하면 된다. 하지만 벡터가 길기만 하면 유사도가 커지는 문제가 있다 따라서, 단위벡터 내적 사용.
- 코사인 유사도(cosine similarity): 단위벡터의 내적. 두 문서의 유사도 계산에 주로 사용.

$$\text{cosine\_similarity}(\mathbf{a}, \mathbf{b}) = \frac{\mathbf{a}}{\|\mathbf{a}\|} \cdot \frac{\mathbf{b}}{\|\mathbf{b}\|} = \cos(\theta) \quad (2.7)$$

행 려  
(matrix)

# 행렬의 기초

Scalar   Vector   Matrix   Tensor

1

$\begin{bmatrix} 1 \\ 2 \end{bmatrix}$

$\begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}$

$\begin{bmatrix} \begin{bmatrix} 1 & 2 \end{bmatrix} & \begin{bmatrix} 3 & 2 \end{bmatrix} \\ \begin{bmatrix} 1 & 7 \end{bmatrix} & \begin{bmatrix} 5 & 4 \end{bmatrix} \end{bmatrix}$

$a$

$\underline{a}, \vec{a}, \boldsymbol{a}, \mathbf{a}$

$\boldsymbol{A}, \mathbf{A}, \mathbf{A}$

# 행렬의 표현

- 행렬은 여러 개의 원소들을 사각형 안에 배치시켜 놓은 것. 사각형이 행(row)을  $m$ 개, 열(column)을  $n$ 개 가질 때 원소의 총 개수는  $mn$ 개가 된다. 또  $i$  번째 행과  $j$  번째 열에 해당되는 원소를  $a_{ij}$  라 하고 이로 이루어지는 행렬을  $A$  라 하면 이는 다음과 같이 표시된다.

$$A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix}$$

$$A = \{a_{ij}\}, \quad (i = 1, 2, \cdots, m; \quad j = 1, 2, \cdots, n)$$



# 벡터와 행렬

- ▷ 벡터(vector) : 행렬의 하나의 특별한 경우라 할 수 있는데,
- $n=1$  인 경우의 행렬,  $m \times 1$  행렬을 열벡터(column vector)라 하고,
  - $m=1$  인 경우의 행렬,  $1 \times n$  행렬을 행벡터(row vector)라 한다.

[Note] 행벡터를 전치하면 열벡터를 얻고, 열벡터를 전치하면 행벡터를 얻는다.

- ▷ 스칼라(scalar) :  $m=n=1$  경우의 원소가 하나인 행렬, eg. 실수

[Note] 스칼라를 전치하면 변화가 없이 같은 스칼라를 얻는다.

[Note] 보통 벡터를 스칼라와 구분하기 위해서 진하게(**bold**) 표현하고, 앞으로 특별히 다른 표시가 없으면 벡터는 열벡터를 의미한다.

# 행렬을 이루는 벡터

## ▷ 다양한 벡터

- 영벡터 : 모든 원소가 0인 벡터,  $\mathbf{0}$ ,
- 일벡터 : 모든 원소가 1인 벡터,  $\mathbf{1}$ ,
- 항등행렬의  $i$ 번째 열벡터 :  $i$ 번째 원소만 1이고 나머지 원소는 모두 0인 벡터,  $\mathbf{e}_i$ ,

eg.  $\mathbf{0} = \begin{pmatrix} 0 \\ 0 \\ 0 \\ 0 \\ 0 \end{pmatrix}, \quad \mathbf{1} = \begin{pmatrix} 1 \\ 1 \\ 1 \\ 1 \\ 1 \end{pmatrix}, \quad \mathbf{e}_2 = \begin{pmatrix} 0 \\ 1 \\ 0 \\ 0 \\ 0 \end{pmatrix}, \quad I_5 = (\mathbf{e}_1, \mathbf{e}_2, \mathbf{e}_3, \mathbf{e}_4, \mathbf{e}_5)$

## ▷ 행렬을 이루는 벡터 :

일반적으로 행렬  $A$ 의  $i$ -번째 행벡터 :  $\mathbf{a}_{i.}' = (a_{i1}, a_{i2}, \dots, a_{in})$ ,

$j$ -번째 열벡터 :  $\mathbf{a}_{.j} = \begin{pmatrix} a_{1j} \\ a_{2j} \\ \vdots \\ a_{mj} \end{pmatrix}$

# 전치행렬(transpose matrix)

- 모든  $(i, j)$  쌍에 대해  $a_{ij}$  원소를  $a_{ji}$  로 전치하여 놓은 행렬  $A$  의 전치행렬(transpose matrix,  $A^T$  또는  $A'$  )이라 한다.

$$A = \{a_{ij}\}_{mn} , \quad A^T = \{a_{ji}\}_{nm}$$

$$A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix}$$

$$A^T = \begin{bmatrix} a_{11} & a_{21} & \cdots & a_{m1} \\ a_{12} & a_{22} & \cdots & a_{m2} \\ \vdots & \vdots & & \vdots \\ a_{1n} & a_{2n} & \cdots & a_{mn} \end{bmatrix}$$

# 전치행렬(transpose matrix)

eg.

$$A = \begin{pmatrix} 2 & 0 & 3 \\ -1 & 2 & 0 \end{pmatrix} \Rightarrow A' = \begin{pmatrix} 2 & -1 \\ 0 & 2 \\ 3 & 0 \end{pmatrix}$$

[Note] 여기서 보는 바와 같이  $A$ 의 첫 번째 행벡터  $\mathbf{a}_{1.}' = (2, 0, 3)$ 를 전치시키면

$A'$ 의 첫 번째 열벡터  $\begin{pmatrix} 2 \\ 0 \\ 3 \end{pmatrix}$ 를 얻을 수 있다.

◎ 예제

$$A = (\mathbf{a}_{.1}, \mathbf{a}_{.2}, \mathbf{a}_{.3}, \mathbf{a}_{.4}) = \begin{pmatrix} 1 & 2 & 3 & 4 \\ 5 & 6 & 7 & 8 \\ 0 & 1 & 2 & 3 \end{pmatrix} \Rightarrow A' = \begin{pmatrix} \mathbf{a}_{.1}' \\ \mathbf{a}_{.2}' \\ \mathbf{a}_{.3}' \\ \mathbf{a}_{.4}' \end{pmatrix} = \begin{pmatrix} 1 & 5 & 0 \\ 2 & 6 & 1 \\ 3 & 7 & 2 \\ 4 & 8 & 3 \end{pmatrix}$$

# 전치행렬(transpose matrix)

$$\mathbf{X} = \begin{pmatrix} 5.1 & 3.5 & 1.4 & 0.2 \\ 4.9 & 3.0 & 1.4 & 0.2 \\ 4.7 & 3.2 & 1.3 & 0.2 \\ 4.6 & 3.1 & 1.5 & 0.2 \\ \vdots & \vdots & \vdots & \vdots \\ 6.2 & 3.4 & 5.4 & 2.3 \\ 5.9 & 3.0 & 5.1 & 1.8 \end{pmatrix} = \begin{pmatrix} x_{1,1} & x_{1,2} & x_{1,3} & x_{1,4} \\ x_{2,1} & x_{2,2} & x_{2,3} & x_{2,4} \\ x_{3,1} & x_{3,2} & x_{3,3} & x_{3,4} \\ x_{4,1} & x_{4,2} & x_{4,3} & x_{4,4} \\ \vdots & \vdots & \vdots & \vdots \\ x_{149,1} & x_{149,2} & x_{149,3} & x_{149,4} \\ x_{150,1} & x_{150,2} & x_{150,3} & x_{150,4} \end{pmatrix}$$

← 행 row

↑  
열 column

- Iris의 설계 행렬을 전치행렬 표기에 따라 표현하면,

$$\mathbf{X} = \begin{pmatrix} \mathbf{x}_1^T \\ \mathbf{x}_2^T \\ \vdots \\ \mathbf{x}_{150}^T \end{pmatrix}$$

# 대칭행렬(symmetric matrix)

- 행렬에서 행과 열의 차원이 같을 때( $m = n$ ) 정방행렬 (정사각행렬, square matrix)이라 한다. 행렬  $A$  가 정방행렬이면서

$$A = A^T$$

가 성립하는 행렬을 대칭행렬(symmetric matrix)이라 한다.

$$A = \begin{bmatrix} 1 & -4 & -5 \\ -4 & 2 & -6 \\ -5 & -6 & 3 \end{bmatrix} = A^T$$

# 대각행렬(diagonal matrix)

- 행렬이 대각요소만으로 이루어진 행렬을 대각행렬(diagonal matrix)이라 하고 대각행렬에서 모든 대각요소가 1인 행렬을 단위행렬(unit matrix 또는 identity matrix)이라 한다.

$$D = \begin{bmatrix} 1 & 0 & \cdots & 0 \\ 0 & 2 & \cdots & 0 \\ \vdots & \vdots & & \vdots \\ 0 & 0 & \cdots & 5 \end{bmatrix}$$

$$I = \begin{bmatrix} 1 & 0 & \cdots & 0 \\ 0 & 1 & \cdots & 0 \\ \vdots & \vdots & & \vdots \\ 0 & 0 & \cdots & 1 \end{bmatrix}$$

# 다항식의 행렬 표현

## ■ 행렬을 이용하면 수학을 간결하게 표현할 수 있음

### ■ 예) 다항식의 행렬 표현

$$f(\mathbf{x}) = f(x_1, x_2, x_3)$$

$$= 2x_1x_1 - 4x_1x_2 + 3x_1x_3 + x_2x_1 + 2x_2x_2 + 6x_2x_3 - 2x_3x_1 + 3x_3x_2 + 2x_3x_3 + 2x_1 + 3x_2 - 4x_3 + 5$$

$$= (x_1 \quad x_2 \quad x_3) \begin{pmatrix} 2 & -4 & 3 \\ 1 & 2 & 6 \\ -2 & 3 & 2 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} + (2 \quad 3 \quad -4) \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} + 5$$

$$= \mathbf{x}^T \mathbf{A} \mathbf{x} + \mathbf{b}^T \mathbf{x} + c$$

## ■ 특수한 행렬들

$$\text{정사각행렬} \begin{pmatrix} 2 & 0 & 1 \\ 1 & 21 & 5 \\ 4 & 5 & 12 \end{pmatrix}, \quad \text{대각행렬} \begin{pmatrix} 50 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 8 \end{pmatrix},$$

$$\text{단위행렬} \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}, \quad \text{대칭행렬} \begin{pmatrix} 1 & 2 & 11 \\ 2 & 21 & 5 \\ 11 & 5 & 1 \end{pmatrix}$$



# 행렬의 덧셈

▷ 두 행렬의 합 : 두 행렬의 차수가 같아야 한다.

$$A = \{a_{ij}\}, \quad B = \{b_{ij}\} \quad m \times n \text{ 행렬}$$

두 행렬의 합의  $(i, j)$ -번째 원소 :  $(A+B)_{i,j} = a_{ij} + b_{ij}$

eg. 
$$A + B = \begin{pmatrix} 4 & 3 \\ -1 & 2 \end{pmatrix} + \begin{pmatrix} 1 & 0 \\ -5 & 2 \end{pmatrix} = \begin{pmatrix} 5 & 3 \\ -6 & 4 \end{pmatrix}$$

▷ 행렬과 스칼라의 곱 : 모든 원소에 스칼라를 곱해서 얻을 수 있다.

$$(\alpha A)_{ij} = \alpha a_{ij}$$

eg. 
$$3 \begin{pmatrix} 4 & 3 \\ -1 & 2 \end{pmatrix} = \begin{pmatrix} 12 & 9 \\ -3 & 6 \end{pmatrix}$$

# 행렬의 곱셈

- 행렬의 곱셈에서는 피승수 행렬의 차원이  $m \times p$  이면 승수 행렬의 행의 차수는  $p$  가 되어야 한다. 즉 피승수 행렬의 열의 수는 승수 행렬의 행의 수와 일치되어야 한다.

$$A_{2 \times 3} \cdot B_{3 \times 2} = C_{2 \times 2}$$

$$A_{2 \times 3} \cdot B_{2 \times 3} \neq C$$

- $2 \times 3$  행렬  $A$  와  $3 \times 2$  행렬  $B$  를 곱한 결과 얻어진 행렬  $C$  의 차원은  $2 \times 2$  가 되며, 곱셈 순서는 다음과 같다.

$$\begin{array}{ccc}
 A & B & C \\
 \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \end{bmatrix} & \cdot \begin{bmatrix} b_{11} & b_{12} \\ b_{21} & b_{22} \\ b_{31} & b_{32} \end{bmatrix} & = \begin{bmatrix} c_{11} & c_{12} \\ c_{21} & c_{22} \end{bmatrix}
 \end{array}$$

$$c_{11} = a_{11}b_{11} + a_{12}b_{21} + a_{13}b_{31}$$

# 행렬의 곱셈

- $A$  행렬의 첫째 행과  $B$  행렬의 첫째 열을 대응되는 것끼리 곱하여 합하면  $C$  행렬의 첫째 행과 첫째 열의 원소  $c_{11}$ 이 얻어진다. 이와 같은 방법으로  $C$  행렬을 구하면 다음과 같다.

$$c_{11} = a_{11}b_{11} + a_{12}b_{21} + a_{13}b_{31}$$

$$c_{12} = a_{11}b_{12} + a_{12}b_{22} + a_{13}b_{32}$$

$$c_{21} = a_{21}b_{11} + a_{22}b_{21} + a_{23}b_{31}$$

$$c_{22} = a_{21}b_{12} + a_{22}b_{22} + a_{23}b_{32}$$

- 일반적으로  $m \times p$  행렬  $A$  와  $p \times n$  행렬  $B$  의 곱  $C = A \cdot B$  의 차원은  $m \times n$  이고, 각 원소는 다음의 식에 의해 계산된다.

$$c_{ij} = \sum_{k=1}^p a_{ik}b_{kj} \quad , \quad \text{for all } i, j$$

# 행렬의 곱셈

▷ 두 행렬의 곱 :  $A$ 와  $B$ 를  $AB$ 로 곱하려면 :  $A$ 의 열의 수 =  $B$ 의 행의 수

$A: m \times p$  행렬,  $B: p \times n$  행렬  $\Rightarrow AB$ 는  $m \times n$

$$A = \begin{pmatrix} a_{11} & a_{12} & \dots & a_{1p} \\ a_{21} & a_{22} & \dots & a_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \dots & a_{mp} \end{pmatrix}, \quad B = \begin{pmatrix} b_{11} & b_{12} & \dots & b_{1n} \\ b_{21} & b_{22} & \dots & b_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ b_{p1} & b_{p2} & \dots & b_{pn} \end{pmatrix}$$

•  $AB$ 의  $(i, j)$ -번째 원소 :  $(AB)_{ij} = \sum_{k=1}^p a_{ik} b_{kj}$

• 행렬에 곱셈에서는 다음과 같은 관계가 성립한다.

$$A \cdot B \neq B \cdot A$$

$$\text{일반적으로 } (A \cdot B)^T = B^T \cdot A^T$$

모든 정방행렬에 대하여  $A \cdot I = I \cdot A = A$  가 성립한다

$$(A \cdot B) \cdot C = A \cdot (B \cdot C)$$

$$C \cdot (A + B) = C \cdot A + C \cdot B$$

# 행렬의 곱셈

◎ 예제 4.2 on p.107

$$A = \begin{pmatrix} 2 & 0 & 3 \\ -1 & 2 & 0 \end{pmatrix}, \quad B = \begin{pmatrix} 1 & 0 \\ 0 & 2 \\ 3 & 1 \end{pmatrix}, \quad C = \begin{pmatrix} 1 & 0 \\ 0 & 2 \end{pmatrix}$$

$$AB = \begin{pmatrix} 2 & 0 & 3 \\ -1 & 2 & 0 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & 2 \\ 3 & 1 \end{pmatrix} = \begin{pmatrix} 11 & 3 \\ -1 & 4 \end{pmatrix}$$

$$ABC = \begin{pmatrix} 11 & 3 \\ -1 & 4 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & 2 \end{pmatrix} = \begin{pmatrix} 11 & 6 \\ -1 & 8 \end{pmatrix}$$

$$3(AB + C) = 3 \left( \begin{pmatrix} 11 & 3 \\ -1 & 4 \end{pmatrix} + \begin{pmatrix} 1 & 0 \\ 0 & 2 \end{pmatrix} \right) = 3 \begin{pmatrix} 12 & 3 \\ -1 & 6 \end{pmatrix} = \begin{pmatrix} 36 & 9 \\ -3 & 18 \end{pmatrix}$$

eg. 앞의  $2 \times 3$  행렬  $A$ 에 대하여  $A'A$ 와  $AA'$ 를 구해보면 다음과 같이 전혀 다른 행렬을 얻게 된다.

$$A = \begin{pmatrix} 2 & 0 & 3 \\ -1 & 2 & 0 \end{pmatrix}, \quad A' = \begin{pmatrix} 2 & -1 \\ 0 & 2 \\ 3 & 0 \end{pmatrix}$$

$$A'A = \begin{pmatrix} 2 & -1 \\ 0 & 2 \\ 3 & 0 \end{pmatrix} \begin{pmatrix} 2 & 0 & 3 \\ -1 & 2 & 0 \end{pmatrix} = \begin{pmatrix} 5 & -2 & 6 \\ -2 & 4 & 0 \\ 6 & 0 & 9 \end{pmatrix}, \quad AA' = \begin{pmatrix} 2 & 0 & 3 \\ -1 & 2 & 0 \end{pmatrix} \begin{pmatrix} 2 & -1 \\ 0 & 2 \\ 3 & 0 \end{pmatrix} = \begin{pmatrix} 13 & -2 \\ -2 & 5 \end{pmatrix}$$

[Note] 행렬  $A$ 가  $n \times n$  정사각행렬일 때  $AA$ 는  $A^2$ 으로 표현한다.

$$(A^2)_{ij} = \sum_{k=1}^n a_{ik} a_{kj} \quad : \quad A \text{의 } i\text{-번째 행벡터와 } A \text{의 } j\text{-번째 열벡터의 곱}$$

# 행렬식(determinant)

- $n \times n$  정방행렬  $A = \{a_{ij}\}$  의 행렬식(determinant)은  $|A|$  (또는  $\det(A)$ ) 로 표시하며, 하나의 실수 값으로 표현된다. 3차 행렬까지의 행렬식은 다음과 같은 방법으로 구할 수 있다.

$$|a_{11}| = a_{11}$$

$$\begin{vmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{vmatrix} = a_{11}a_{22} - a_{12}a_{21}$$

$$\begin{vmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{vmatrix} = a_{11}a_{22}a_{33} + a_{12}a_{23}a_{31} + a_{13}a_{32}a_{21} \\ - a_{13}a_{22}a_{31} - a_{12}a_{21}a_{33} - a_{11}a_{32}a_{23}$$

행렬식이란 정사각행렬에 어떤 특정한 방법으로 하나의 수를 대응시키는 함수이다. 행렬식은 역행렬이 존재하는지를 판단하는 근거가 되며, 문자의 수와 식의 수가 같은 연립일차방정식의 근이 유일하게 존재하는지를 결정하는 데 중요한 역할을 한다.

행렬식의 영어 표현인 determinant는 determine에서 나온 것으로서 '결정'한다는 뜻을 내포한다.

# 행렬식(determinant)

행렬식에 대해서는 다음과 같은 관계가 성립한다.

- 행렬  $A$ 와  $B$ 가 모두 정방행렬이면  $|AB| = |BA| = |A||B|$  이다.
- $|A| = |A^T|$  이다.
- 행렬  $A$ 가 대각행렬이면  $|A| = a_{11} \times a_{22} \times \cdots \times a_{nn}$  이다.
- 행렬  $A$ 의 행벡터나 열벡터의 원소가 모두 0일 때,  $|A| = 0$  이다.
- 행렬  $A$ 가  $n \times n$  정방행렬이면 상수  $k$  에 대하여  $|kA| = k^n |A|$  이다.
- $A = \begin{pmatrix} 2 & -1 \\ 21 & 2 \end{pmatrix} \Rightarrow |A| = 4 - (-21) = 25$
- $\left| \begin{pmatrix} 5 & 2 \\ 2 & 5 \end{pmatrix} - \lambda \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \right| = \left| \begin{pmatrix} 5-\lambda & 2 \\ 2 & 5-\lambda \end{pmatrix} \right| = (5-\lambda)^2 - 4 = (\lambda-3)(\lambda-7)$

# 역행렬(inverse matrix)

- $n \times n$  정방행렬  $A = \{a_{ij}\}$  의 행렬식이 0 이 아닐 때 (즉,  $|A| \neq 0$ 이면), 만약  $AB = BA = I_n$  을 만족시키는 행렬  $B$  가 존재한다면, 행렬  $B$  를 행렬  $A$  의 역행렬(inverse matrix)이라 하고  $A^{-1}$  로 표현한다.

$$A \text{의 역행렬 } A^{-1} \leftrightarrow AA^{-1} = A^{-1}A = I$$


$$\text{eg. } A = \begin{pmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{pmatrix} \Rightarrow A^{-1} = \frac{1}{|A|} \begin{pmatrix} a_{22} & -a_{12} \\ -a_{21} & a_{11} \end{pmatrix}$$

$$A = \begin{pmatrix} 1 & 3 \\ 2 & 4 \end{pmatrix} \Rightarrow |A| = -2, \quad A^{-1} = \frac{1}{(-2)} \begin{pmatrix} 4 & -3 \\ -2 & 1 \end{pmatrix} = \begin{pmatrix} -2 & 1.5 \\ 1 & -0.5 \end{pmatrix}$$




# 역행렬(inverse matrix)

## ■ 역행렬의 원리



(a) 역수의 원리



(b) 역행렬의 원리

그림 2-9 역행렬

- 정사각행렬  $A$ 의 역행렬  $A^{-1}$

$$A^{-1}A = AA^{-1} = I$$

- 예를 들어,  $\begin{pmatrix} 2 & 1 \\ 6 & 4 \end{pmatrix}$ 의 역행렬은  $\begin{pmatrix} 2 & -0.5 \\ -3 & 1 \end{pmatrix}$

# 정칙행렬(nonsingular matrix)

- $n \times n$  정방행렬  $A = \{a_{ij}\}$  에 대해  $AB = I$  를 만족시키는 행렬  $B$ 가 유일하게 존재하면 행렬  $B$ 는  $A^{-1}$ 이 되고, 이 때 행렬  $A$ 를 정칙행렬(nonsingular matrix) 이라 한다. 그렇지 않으면 행렬  $A$ 를 비정칙행렬(특이행렬, singular matrix)이라 한다.
  - $A$  가 정칙행렬이 되기 위한 필요 충분 조건은  $|A| \neq 0$  이다.
  - 또  $A$  가 정칙행렬이면,  $|A^{-1}| = |A|^{-1}$  이다.
  - 정칙(nonsingular)행렬 : 행렬식이 0이 아닌 정사각행렬
  - 특이(singular, 비정칙)행렬 : 행렬식이 0인 정사각행렬
- ▷ 역행렬  $A$  : 정칙행렬일 때 역행렬이 존재한다. 즉, 어떤 행렬의 역행렬이 존재하기 위해서는 그 행렬이 정칙행렬이어야 한다.

# 직교행렬(orthogonal matrix)

- $n \times n$  정방행렬  $A = \{a_{ij}\}$  의 역행렬  $A^{-1}$  이 전치행렬  $A^T$  와 같으면, 행렬  $A$ 를 직교행렬(orthogonal matrix)이라 한다.

$$\text{즉, 직교행렬 } A \leftrightarrow A^{-1} = A^T$$

- $A$  가 직교행렬이면 다음이 성립한다.

$$AA^T = A^T A = I$$

- $n \times n$  정방행렬  $A = \{a_{ij}\}$ 의 각 열벡터를  $\underline{a}_1, \underline{a}_2, \dots, \underline{a}_n$  이라 하면 행렬  $A$  가 직교행렬이기 위한 필요충분조건은 다음과 같다.


$$\underline{a}_i^T \underline{a}_j = \begin{cases} 0 & \text{for } i \neq j \\ 1 & \text{for } i = j \end{cases}$$

즉, 각 열벡터는 길이가 1이고 다른 열벡터와 직교한다. 이러한 벡터를 정규직교(직교정규, orthonormal) 벡터라고 한다.

고유값과 고유벡터

# 행렬 변환(벡터의 선형변환)

## 행렬 변환의 공간적 표현




- $n$ 차원 벡터공간  $R^n$  안의 임의 벡터를  $m$ 차원 벡터공간  $R^m$  안의 임의 벡터로 보내는 변환
  - $R^n$  안의 임의 벡터  $\mathbf{x}$ 를  $R^m$  안의 벡터  $T_A(\mathbf{x}) = A \mathbf{x}$  로의 대응 규칙
    - .  $T_A$  : 행렬변환
    - .  $A$  :  $m \times n$  행렬
    - .  $R^n$  : 변환  $T_A$ 의 정의역
    - .  $R^m$  : 변환  $T_A$ 의 공역
    - . 치역은, 정의역 모든 원소들의 상으로 만 이루어진 공역의 부분집합

# 행렬 변환(벡터의 선형변환)

## 비례변환

$T$ 는  $R^2$  안의 벡터  $\mathbf{x} = (x_1, x_2)$ 를  $R^2$  안의 벡터  $2\mathbf{x} = (2x_1, 2x_2)$ 로 사상하는 변환

$$\begin{aligned}(x_1, x_2) &\xrightarrow{T} (2x_1, 2x_2) && \text{또는 } T(\mathbf{x}) = 2\mathbf{x} \\ \mathbf{x} &\xrightarrow{T} 2\mathbf{x}\end{aligned}$$


If  $\mathbf{x} = (-1, 3)$ ,  $T(\mathbf{x}) = (-2, 6)$    $\mathbf{x} = (-1, 3)$ 의 상(像)

## 행렬곱셈의 변환

- $T_A$ 는  $R^2$  안의  $2 \times 1$  벡터  $\mathbf{x}$ 를  $R^3$  안의  $3 \times 1$  벡터  $A\mathbf{x}$ 로 보내는 변환

$$\begin{aligned}T_A(\mathbf{x}) &= A\mathbf{x} \\ \mathbf{x} &\xrightarrow{T_A} A\mathbf{x}\end{aligned} \quad A\mathbf{x} = \begin{bmatrix} 1 & -1 \\ 2 & 5 \\ 3 & 4 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} x_1 - x_2 \\ 2x_1 + 5x_2 \\ 3x_1 + 4x_2 \end{bmatrix}$$

$$\text{또는 } T_A\left(\begin{bmatrix} x_1 \\ x_2 \end{bmatrix}\right) = \begin{bmatrix} x_1 - x_2 \\ 2x_1 + 5x_2 \\ 3x_1 + 4x_2 \end{bmatrix}$$


$$T_A\left(\begin{bmatrix} -1 \\ 3 \end{bmatrix}\right) = \begin{bmatrix} -4 \\ 13 \\ 9 \end{bmatrix} \quad \text{ } \mathbf{x} = \begin{bmatrix} 1 \\ -3 \end{bmatrix} \text{의 상(像)}$$

# 기하 변환(벡터의 선형변환)

## 반사변환

• y축 반사


$$A = \begin{bmatrix} -1 & 0 \\ 0 & 1 \end{bmatrix}$$



$$T\left(\begin{bmatrix} x \\ y \end{bmatrix}\right) = \begin{bmatrix} -1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix}$$

• x축 반사


$$A = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}$$



$$T\left(\begin{bmatrix} x \\ y \end{bmatrix}\right) = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix}$$

• 직선  $y=x$  반사

$$A = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$$



$$T\left(\begin{bmatrix} x \\ y \end{bmatrix}\right) = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix}$$

# 1. 벡터의 선형변환


- 아래 행렬  $\mathbf{A}$  는  $\mathbb{R}^n \rightarrow \mathbb{R}^n$ 로 변환시키는 선형변환  $\mathbf{y} = \mathbf{A}\mathbf{x}$ 에 사용된 행렬이며 아래와 같다.

$$\begin{pmatrix} y_1 \\ y_2 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$$


- 위 선형변환은 아래 그림과 같이 정사각형을 평행사변형으로 변형시키는 역할을 한다.

$$\begin{pmatrix} 1 \\ 2 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

$$\begin{pmatrix} 0 \\ 1 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} 0 \\ 1 \end{pmatrix}$$







- 예를 들어, 점  $(1, 1)$  에 해당되는 벡터  $\mathbf{x}'$  의 경우 점  $(1, 2)$  에 이르는 벡터  $\mathbf{y}'$  으로 변환된다.

$$\mathbf{y}' = \mathbf{A}\mathbf{x}'$$

$$\begin{pmatrix} 1 \\ 2 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

- 그러나 점  $(0, 1)$ 에 해당되는  $\mathbf{x}''$ 의 경우는  $\mathbf{A}\mathbf{x} = 1 \cdot \mathbf{x}''$  를 만족하게 되며, 이 변환된 벡터는 변환 이전 벡터에 상수배 만큼만 변하게 된다. 이 경우,  $\lambda = 1$  이  $\mathbf{A}$  의 고유값이 되고  $\mathbf{x}''$  가  $\lambda = 1$  에 대한  $\mathbf{A}$  의 고유벡터가 된다.

$$\begin{pmatrix} 0 \\ 1 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} 0 \\ 1 \end{pmatrix}$$

## 2. 고유값(Eigenvalue)과 고유벡터(Eigenvector)


- 정방행렬  $\mathbf{A}_{n \times n}$ 이  $\mathbb{R}^n \rightarrow \mathbb{R}^n$ 의 선형변환행렬 이라고 할 때,  $\mathbf{y} = \mathbf{Ax}$ 라는 선형변환이 어떤 벡터  $\mathbf{x}$ 에서는 아래와 같이 방향은 같고 크기만 바뀌는 변환이 되기도 한다.

$$\mathbf{Ax} = \lambda \mathbf{x}, \quad (\mathbf{x} \neq \mathbf{0})$$

- 이 때, 스칼라  $\lambda$ 를 "행렬  $\mathbf{A}$ 의 고유값(eigenvalue)"이라 하고, 벡터  $\mathbf{x}$ 를 "고유값  $\lambda$ 에 대한 고유벡터(eigenvector)"라고 말한다.
- 정방행렬  $\mathbf{A}$ 에 대하여,  $\mathbf{Ax} = \lambda \mathbf{x}$ 가 성립할 때,  $\lambda$ 를 고유값(eigenvalue),  $\mathbf{x}$ 를  $\lambda$ 에 따른 고유벡터(eigenvector)라고 한다. 이 때,  $\mathbf{x}$ 는 영이 아닌 벡터이다.

서로 같은 벡터라 함은 '크기'와 '방향'이 둘다 같은 벡터임을 의미합니다.

- 참고: 벡터는 크기와 방향을 가진다.




## 2. 고유값(Eigenvalue)과 고유벡터(Eigenvector)

$A$  :  $n$ 차의 정사각행렬

다음을 만족할 때  $\lambda$ 를  $A$ 의 **고유값**이라 하고  $x$ 를  $\lambda$ 에 대응하는  $A$ 의 **고유벡터**라한다.


$$\Rightarrow Ax = \lambda x$$



## 2. 고유값(Eigenvalue)과 고유벡터(Eigenvector)

- 또 다른 예) 점  $(2, 2)$ 에 해당되는  $\mathbf{x}_2$ 의 경우는  $\mathbf{A}\mathbf{x}_1 = 2 \cdot \mathbf{x}_1 = \mathbf{x}_2$ 를 만족하게 되며, 이 변환된 벡터는 변환 이전 벡터에 상수배 만큼만 변하게 된다.  
이 경우,  $\lambda = 2$ 가  $\mathbf{A}$ 의 고유값이 되고  $\mathbf{x}_1$ 이  $\lambda = 2$ 에 대한  $\mathbf{A}$ 의 고유벡터가 된다.

$$\begin{pmatrix} 2 \\ 2 \end{pmatrix} = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$



## 2. 고유값(Eigenvalue)과 고유벡터(Eigenvector)

정방행렬 A에 대하여 다음이 성립하는 0이 아닌 벡터  $x$ 가 존재할 때

$$Ax = \lambda x \quad (\text{상수 } \lambda)$$

$$\begin{pmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{n1} & \cdots & a_{nn} \end{pmatrix} \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix} = \lambda \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix}$$

상수  $\lambda$ 를 행렬  $A$ 의 고유값 (eigenvalue),

$x$ 를 이에 대응하는 고유벡터 (eigenvector) 라고 함

## 2. 고유값(Eigenvalue)과 고유벡터(Eigenvector)

예제:

정방행렬 A (square matrix A)	$\begin{pmatrix} 4 & 2 \\ 3 & 5 \end{pmatrix}$	
고유값 $\lambda$ (eigenvalue)	$\lambda = 7$	$\lambda = 2$
고유벡터 $x$ (eigenvector)	$\begin{pmatrix} 2 \\ 3 \end{pmatrix}$	$\begin{pmatrix} -1 \\ 1 \end{pmatrix}$

출처: [https://rstudio-pubs-static.s3.amazonaws.com/346037\\_78713fb40a144e749eaa6dab773a3571.html](https://rstudio-pubs-static.s3.amazonaws.com/346037_78713fb40a144e749eaa6dab773a3571.html)

## 2. 고유값(Eigenvalue)과 고유벡터(Eigenvector)

행렬 A에 대한 고유값, 고유벡터

$$A x = \lambda x$$
$$\begin{pmatrix} 4 & 2 \\ 3 & 5 \end{pmatrix} \begin{pmatrix} 2 \\ 3 \end{pmatrix} = 7 \begin{pmatrix} 2 \\ 3 \end{pmatrix}$$

$$\begin{pmatrix} 4 & 2 \\ 3 & 5 \end{pmatrix} \begin{pmatrix} 2 \\ 3 \end{pmatrix}$$
$$= \begin{pmatrix} 4 \times 2 + 2 \times 3 \\ 3 \times 2 + 5 \times 3 \end{pmatrix}$$
$$= \begin{pmatrix} 14 \\ 21 \end{pmatrix}$$
$$= 7 \begin{pmatrix} 2 \\ 3 \end{pmatrix}$$

square matrix

$$Ax = \lambda x$$

eigenvalue


eigenvector

$$A x = \lambda x$$
$$\begin{pmatrix} 4 & 2 \\ 3 & 5 \end{pmatrix} \begin{pmatrix} -1 \\ 1 \end{pmatrix} = 2 \begin{pmatrix} -1 \\ 1 \end{pmatrix}$$

$$\begin{pmatrix} 4 & 2 \\ 3 & 5 \end{pmatrix} \begin{pmatrix} -1 \\ 1 \end{pmatrix}$$
$$= \begin{pmatrix} 4 \times (-1) + 2 \times 1 \\ 3 \times (-1) + 5 \times 1 \end{pmatrix}$$
$$= \begin{pmatrix} -2 \\ 2 \end{pmatrix}$$
$$= 2 \begin{pmatrix} -1 \\ 1 \end{pmatrix}$$

## 2. 고유값(Eigenvalue)과 고유벡터(Eigenvector)

왼쪽의 A, B, C, D, E 의 좌표점들이 오른쪽에는 A', B', C', D', E' 로 정방행렬  $A = \begin{pmatrix} 4 & 2 \\ 3 & 5 \end{pmatrix}$ 에 의해 변환되었습니다. 계산 예시로 B (2, 3)  $\rightarrow$  B' (14, 21)와 D (-1, 1)  $\rightarrow$  D' (-2, 2) 만 아래 그래프 위에 겹쳐서 제시해보았습니다.





### 3. 고유값과 고유벡터 구하는 방법

◆ 행렬의 고유값을 구하기 위한 행렬식(determinant)의 사용법

- $\mathbf{Ax} = \lambda \mathbf{x}$  이므로 정리하면  $(\mathbf{A} - \lambda \mathbf{I})\mathbf{x} = 0$  가 된다.

이 때, 고유벡터  $\mathbf{x}$  는 위 방정식을 만족하는 0이 아닌 벡터를 의미한다.

위 방정식이 0이 아닌 해를 갖기 위한 조건은 행렬  $\mathbf{A} - \lambda \mathbf{I}$  가 비정칙행렬(singular)임을 의미하며 이는 행렬식(determinant)  $|\mathbf{A} - \lambda \mathbf{I}| = 0$  임을 의미한다.

왜냐하면,  $|\mathbf{A} - \lambda \mathbf{I}| \neq 0$  이라면  $(\mathbf{A} - \lambda \mathbf{I})^{-1}$  가 존재하므로,  $\mathbf{x} = (\mathbf{A} - \lambda \mathbf{I})^{-1} 0 = 0$  가 되어  $\mathbf{x}$  가 영 아닌 벡터라는 가정에 모순된다.

그러므로  $|\mathbf{A} - \lambda \mathbf{I}| = 0$  을 만족시키는  $\lambda$  가 행렬  $\mathbf{A}$  의 고유값이 될 것이다.

### 3. 고유값과 고유벡터 구하는 방법

#### ◆ 행렬식(determinant)의 특징

- 행렬  $A$  의 고유값은

$$p(\lambda) = |(\mathbf{A} - \lambda \mathbf{I})| = 0$$

을 만족하는  $\lambda$  를 구하면서 얻게 된다. 여기서  $p(\lambda) = |(\mathbf{A} - \lambda \mathbf{I})| = 0$  을 이 행렬  $\mathbf{A}$  의 특성화방정식(characteristic equation)이라고 한다.

### 3. 고유값과 고유벡터 구하는 방법

#### ◆ 고유벡터를 구하는 방법

- 고유값이 주어졌을 때, 고유벡터를 구하는 방법은

$$\mathbf{A}\mathbf{x} = \lambda\mathbf{x}$$

즉,

$$\underbrace{(\mathbf{A} - \lambda\mathbf{I}_n)}_M \mathbf{x} = \mathbf{0}$$

을 만족하는  $\mathbf{x}$  를 구하는 방법과 일치한다. 따라서, 위 방정식  $M\mathbf{x} = \mathbf{0}$  의 해를 구하기 위해 확장행렬  $(M | \mathbf{0})$ 에 대한 가우스-조단 알고리즘을 사용하여 해를 구한다.

- 행렬  $\mathbf{A}$  의 고유값이  $\lambda$  일 때, 고유벡터는  $(\mathbf{A} - \lambda\mathbf{I}_n)\mathbf{x} = \mathbf{0}$  을 만족하는  $\mathbf{x}$  를 구함으로써 얻어진다.

### 3. 고유값과 고유벡터 구하는 방법

- 일반적으로 고유벡터는 단위길이를 갖도록 정규화된 고유벡터

$$\mathbf{e}_i = \mathbf{x}_i / \sqrt{\mathbf{x}_i' \mathbf{x}_i} \quad \text{로 표시된다.}$$

행렬  $\mathbf{A}$  가  $n \times n$  정방행렬이면, 행렬  $\mathbf{A}$  에서  $n$ 개 고유값과 정규화된 고유벡터를 구할 수 있다.

$$((\lambda_1, \mathbf{e}_1), (\lambda_2, \mathbf{e}_2), \dots, (\lambda_n, \mathbf{e}_n))$$

이 때  $\mathbf{A}$  가 정방행렬이면서 **대칭행렬**이면,  $n$ 개의 정규화된 고유벡터들은 단위 벡터를 갖고 서로 직교를 이룬다. 이와 같은 성질을 벡터의 내적으로 표시하면 다음과 같다.

$$\mathbf{e}_1' \mathbf{e}_1 = \mathbf{e}_2' \mathbf{e}_2 = \dots = \mathbf{e}_n' \mathbf{e}_n = 1$$

$$\mathbf{e}_i' \mathbf{e}_j = 0 \quad (i \neq j)$$

### 3. 고유값과 고유벡터 구하는 방법

#### Example 1 :

- 행렬  $\mathbf{A} = \begin{pmatrix} 1 & 2 \\ 2 & -2 \end{pmatrix}$  의 고유값과 고유 벡터는? (행렬  $\mathbf{A}$  는 대칭행렬)

Sol) 특성화 방정식을 구하면 다음과 같다.

$$p(\lambda) = |\mathbf{A} - \lambda \mathbf{I}| = \left| \begin{pmatrix} 1 & 2 \\ 2 & -2 \end{pmatrix} - \lambda \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \right| = \left| \begin{pmatrix} 1-\lambda & 2 \\ 2 & -2-\lambda \end{pmatrix} \right| = 0$$

이는

$$p(\lambda) = (1-\lambda)(-2-\lambda) - 2*2 = -2 - \lambda + 2\lambda + \lambda^2 - 4 = \lambda^2 + \lambda - 6$$

$$\Rightarrow p(\lambda) = 0$$

$$\Rightarrow \lambda^2 + \lambda - 6 = 0$$

$$\Rightarrow (\lambda - 2)(\lambda + 3) = 0$$

$$\Rightarrow \lambda = 2 \quad \text{또는} \quad \lambda = -3$$

### 3. 고유값과 고유벡터 구하는 방법

#### Example 1 (계속) :

- 행렬  $A = \begin{pmatrix} 1 & 2 \\ 2 & -2 \end{pmatrix}$  의 고유값과 고유 벡터는? (행렬  $A$  는 대칭행렬)

Sol)  $\lambda_1 = 2, \lambda_2 = -3$

(1)  $\lambda_1 = 2$  에 대응하는 고유벡터  $\underline{x}_1 = \begin{pmatrix} x_{11} \\ x_{12} \end{pmatrix}$  는

$$\begin{pmatrix} 1 & 2 \\ 2 & -2 \end{pmatrix} \begin{pmatrix} x_{11} \\ x_{12} \end{pmatrix} = 2 \begin{pmatrix} x_{11} \\ x_{12} \end{pmatrix} \rightarrow \begin{pmatrix} x_{11} + 2x_{12} \\ 2x_{11} - 2x_{12} \end{pmatrix} = \begin{pmatrix} 2x_{11} \\ 2x_{12} \end{pmatrix} \rightarrow \begin{matrix} x_{11} - 2x_{12} = 0 \\ 2x_{11} - 4x_{12} = 0 \end{matrix}$$
$$\rightarrow x_{11} = 2x_{12} \quad (x_{11} = 0 \text{ 이 아닌 상수})$$

무수히 많은  $x_{11} = 2x_{12}$  중에 하나는  $\underline{x}_1 = \begin{pmatrix} x_{11} \\ x_{12} \end{pmatrix} = \begin{pmatrix} 2 \\ 1 \end{pmatrix}$  이고,

정규화된 첫 번째 고유벡터는  $\underline{e}_1 = \frac{1}{\sqrt{5}} \begin{pmatrix} 2 \\ 1 \end{pmatrix} = \begin{pmatrix} 2/\sqrt{5} \\ 1/\sqrt{5} \end{pmatrix} = \begin{pmatrix} 0.8944 \\ 0.4472 \end{pmatrix}$ 이다.

### 3. 고유값과 고유벡터 구하는 방법

#### Example 1 (계속) :

- 행렬  $A = \begin{pmatrix} 1 & 2 \\ 2 & -2 \end{pmatrix}$  의 고유값과 고유 벡터는? (행렬  $A$  는 대칭행렬)

$$\text{Sol) } \lambda_1 = 2, \quad \lambda_2 = -3$$

(2)  $\lambda_2 = -3$  에 대응하는 고유벡터  $\underline{\mathbf{x}}_2 = \begin{pmatrix} x_{21} \\ x_{22} \end{pmatrix}$  는

$$\begin{aligned} \begin{pmatrix} 1 & 2 \\ 2 & -2 \end{pmatrix} \begin{pmatrix} x_{21} \\ x_{22} \end{pmatrix} &= -3 \begin{pmatrix} x_{21} \\ x_{22} \end{pmatrix} \rightarrow \begin{pmatrix} x_{21} + 2x_{22} \\ 2x_{21} - 2x_{22} \end{pmatrix} = \begin{pmatrix} -3x_{21} \\ -3x_{22} \end{pmatrix} \rightarrow \begin{aligned} 4x_{21} + 2x_{22} &= 0 \\ 2x_{21} + x_{22} &= 0 \end{aligned} \\ &\rightarrow 2x_{21} = -x_{22} \quad (x_{22} = 0 \text{ 이 아닌 상수}) \end{aligned}$$

무수히 많은  $2x_{21} = -x_{22}$  중에 하나는  $\underline{\mathbf{x}}_2 = \begin{pmatrix} x_{21} \\ x_{22} \end{pmatrix} = \begin{pmatrix} 1 \\ -2 \end{pmatrix}$  이고,

정규화된 두 번째 고유벡터는  $\underline{\mathbf{e}}_2 = \frac{1}{\sqrt{5}} \begin{pmatrix} 1 \\ -2 \end{pmatrix} = \begin{pmatrix} 1/\sqrt{5} \\ -2/\sqrt{5} \end{pmatrix} = \begin{pmatrix} 0.4472 \\ -0.8944 \end{pmatrix}$  이다.

두 개의 정규화된 고유벡터의 내적  $\underline{\mathbf{e}}_1^T \underline{\mathbf{e}}_2 = 0$  이므로 두 정규화된 고유벡터는 서로 직교이며 독립이다 (행렬  $A$  가 정방행렬이면서 대칭).

### 3. 고유값과 고유벡터 구하는 방법

**Example2 :** (행렬  $A$  는 대칭행렬이 아님)

행렬  $A = \begin{pmatrix} 2 & 2 \\ 1 & 3 \end{pmatrix}$  이라 하면 고유값은  $\begin{vmatrix} 2-\lambda & 2 \\ 1 & 3-\lambda \end{vmatrix} = (\lambda^2 - 5\lambda + 6) - 2 = 0 \Rightarrow \lambda = 4, 1$

$\lambda = 4$  에 대응하는 고유 벡터  $\underline{u}_1 = \begin{pmatrix} u_{11} \\ u_{12} \end{pmatrix}$  은

$$\begin{pmatrix} 2 & 2 \\ 1 & 3 \end{pmatrix} \begin{pmatrix} u_{11} \\ u_{12} \end{pmatrix} = 4 \begin{pmatrix} u_{11} \\ u_{12} \end{pmatrix} \Rightarrow \begin{pmatrix} 2u_{11} + 2u_{12} \\ u_{11} + 3u_{12} \end{pmatrix} = \begin{pmatrix} 4u_{11} \\ 4u_{12} \end{pmatrix}$$

$$\Rightarrow \begin{cases} -2u_{11} + 2u_{12} = 0 \\ -3u_{11} + 3u_{12} = 0 \end{cases} \Rightarrow u_{11} = u_{12} \quad (u_{11} = 0 \text{ 이 아닌 상수})$$

$\lambda = 1$  에 대응하는 고유벡터  $\underline{u}_2 = \begin{pmatrix} u_{21} \\ u_{22} \end{pmatrix}$  라 하면

$$\begin{pmatrix} 2 & 2 \\ 1 & 3 \end{pmatrix} \begin{pmatrix} u_{21} \\ u_{22} \end{pmatrix} = 1 \begin{pmatrix} u_{21} \\ u_{22} \end{pmatrix} \Rightarrow \begin{pmatrix} 2u_{21} + 2u_{22} \\ u_{21} + 3u_{22} \end{pmatrix} = \begin{pmatrix} u_{21} \\ u_{22} \end{pmatrix}$$

$$\Rightarrow \begin{cases} u_{21} + 2u_{22} = 0 \\ u_{21} + 2u_{22} = 0 \end{cases} \Rightarrow u_{21} = -2u_{22}$$



### 3. 고유값과 고유벡터 구하는 방법

#### Example 3 :

◎ 예제 5.16 on p.166

$$A = \begin{pmatrix} 2 & -1 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}$$

$$\det(A - \lambda I) = \det \begin{pmatrix} (2-\lambda) & -1 & 0 \\ 0 & (1-\lambda) & 0 \\ 0 & 0 & (1-\lambda) \end{pmatrix} = (2-\lambda)(1-\lambda)^2 = 0$$

$\Rightarrow$  고유값 :  $\lambda = 1, 2$  (1은 중근)

•  $\lambda = 2$ 에 대하여 :  $A\mathbf{x} - 2I\mathbf{x} = (A - 2I)\mathbf{x} = \begin{pmatrix} 0 & -1 & 0 \\ 0 & -1 & 0 \\ 0 & 0 & -1 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \mathbf{0}$

$\Rightarrow x_2 = 0, x_3 = 0 \Rightarrow$  고유벡터 :  $\mathbf{x} = (a, 0, 0)'$ , eg.  $\mathbf{x} = (1, 0, 0)'$

•  $\lambda = 1$ 에 대하여 :  $A\mathbf{x} - I\mathbf{x} = (A - I)\mathbf{x} = \begin{pmatrix} 1 & -1 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \mathbf{0}$

$\Rightarrow x_1 = x_2 \Rightarrow$  고유벡터 :  $\mathbf{x} = (a, a, b)'$ , eg.  $\mathbf{x} = (1, 1, 0)'$ ,  $\mathbf{x} = (0, 0, 1)'$

## 4. 고유값과 고유벡터의 성질

정방 행렬  $\mathbf{A}$  의 고유값이  $\lambda$ , 고유벡터가  $\mathbf{x}$ 라고 할 때, 임의의 상수  $c$ 에 대하여,

$$\mathbf{A}(c\mathbf{x}) = \lambda(c\mathbf{x})$$

가 성립하므로, 고유값  $\lambda$  에 대한 고유벡터는  $\mathbf{x}$  뿐 아니라  $c\mathbf{x}$ 도 된다.

따라서, 고유값에 대한 고유벡터는 무한개 존재한다. 모든 상수배가 고유벡터이다.

그 중에서 정규화된 고유벡터는  $\mathbf{e}_i = \mathbf{x}_i / \sqrt{\mathbf{x}_i' \mathbf{x}_i}$  이다.

만약  $\mathbf{A}$  가 대칭행렬인 경우 서로 다른 고유벡터는 서로 직교한다.

$$\text{즉, } \mathbf{e}_i' \mathbf{e}_j = 0 \quad (i \neq j)$$

또한, 임의의 상수가  $c$  일때  $c\mathbf{A}$  의 고유값은  $c\lambda$  이다.

## 4. 고유값과 고유벡터의 성질

- 정방행렬의 고유값과 고유벡터는 행렬의 여러 가지 성질과 밀접한 연관이 있다. 그 중에서 행렬식(determinant)과 궤적(trace)에 대한 성질이 있다.
- 행렬  $\mathbf{A}$ 의 고유값이  $\{\lambda_i\}_{i=1}^n$ 라고 하면 다음과 같은 성질이 성립한다.

$$i) \quad \text{tr}(\mathbf{A}) = \sum_{i=1}^n \lambda_i$$

$$ii) \quad \det(\mathbf{A}) = \prod_{i=1}^n \lambda_i$$

## 4. 고유값과 고유벡터의 성질

- Proof)  
다음 행렬의 고유값을 생각해보자.

$$\mathbf{A} = \begin{pmatrix} a & b \\ c & d \end{pmatrix}$$

고유값을 구해보면

$$\begin{aligned} |(\mathbf{A} - \lambda \mathbf{I})| &= \left| \begin{pmatrix} a - \lambda & b \\ c & d - \lambda \end{pmatrix} \right| \\ &= \lambda^2 - (a + d)\lambda + (ad - bc) \end{aligned}$$

가 되어 특성방정식이

$$\begin{aligned} p(\lambda) &= \lambda^2 - (a + d)\lambda + (ad - bc) \\ &= (\lambda - \lambda_1)(\lambda - \lambda_2) \end{aligned}$$

라고 표현 가능하다. 이는  $p(\lambda)$  전개를 통해

$$\lambda_1 + \lambda_2 = a + d = \text{tr}(\mathbf{A})$$

$$\lambda_1 \cdot \lambda_2 = ad - bc = |\mathbf{A}|$$

임을 확인할 수 있다.

## 4. 고유값과 고유벡터의 성질

◎ 예제 5.19 on 170

$A = \begin{pmatrix} 5 & -3 & 3 \\ 4 & -2 & 3 \\ 4 & -4 & 5 \end{pmatrix}$ 의 고유값은 1, 2, 5이므로

- $\text{tr}(A) = 5 - 2 + 5 = 8 = 1 + 2 + 5 = \lambda_1 + \lambda_2 + \lambda_3$
- $\det(A) = 5(-10 + 12) + 3(20 - 12) + 3(-16 + 8) = 10 = (1)(2)(5) = \lambda_1 \lambda_2 \lambda_3$

◎ #5.32 on p.198  $\det(A) = 6$ ,  $\lambda: 1, 2, 3$

$$A = \begin{pmatrix} 1 & 0 & 0 \\ -1 & 3 & 0 \\ -1 & -1 & 2 \end{pmatrix} \Rightarrow \det(A) = 6, \quad \lambda: 1, 2, 3$$

## 4. 고유값과 고유벡터의 성질

- 만일 행렬  $\mathbf{A}$ 의 고유값 중 하나 이상의 0이 존재하면 행렬  $\mathbf{A}$ 는 비정칙행렬(singular matrix)로서 역행렬이 존재하지 않는다.

proof)

고유값 중에 하나 이상이 0이 존재한다고 가정했을 때, 행렬식은

$$|\mathbf{A}| = \prod_{i=1}^n \lambda_i = 0$$

이 되므로  $\mathbf{A}$ 는 비정칙행렬이다.

- 행렬  $\mathbf{A}$ 의 고유값이  $\lambda_1, \lambda_2, \dots, \lambda_n$ 이고 고유벡터가  $\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_n$ 일 때, 만일 고유값들이 서로 다른 값이면 ( $\lambda_1 \neq \lambda_2 \neq \dots \neq \lambda_n$ ), 고유벡터  $\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_n$ 은 선형독립(linearly independent)이다.

$n$ 차 대칭 정방행렬  $\mathbf{A}$ 의 어떤 두 개의 고유값  $\lambda_1, \lambda_2$ 이고, 이에 대응하는 고유벡터가  $\mathbf{x}_1, \mathbf{x}_2$ 라 하면,  $\lambda_1 \neq \lambda_2$ 일 때  $\mathbf{x}_1$ 과  $\mathbf{x}_2$ 는 직교한다.  
즉,  $\mathbf{x}_1^T \cdot \mathbf{x}_2 = 0$ 이다.

## 5. 대칭-양정치행렬의 고유값

- 정방행렬  $\mathbf{A}_{n \times n}$  에 대해서  $\mathbf{x}'\mathbf{A}\mathbf{x}$  를 행렬  $\mathbf{A}$  의 이차형식 (quadratic form) 이라 부른다. 이차형식은 하나의 값(스칼라)으로 나타난다. 일반적으로

$$\mathbf{x}'\mathbf{A}\mathbf{x} = \sum_{i=1}^n a_{ii}x_i^2 + 2\sum_{i=1}^n \sum_{j=i+1}^n a_{ij}x_i x_j \quad \text{로 표시된다.}$$

$$\mathbf{A} = \begin{pmatrix} 1 & -2 \\ -2 & 5 \end{pmatrix}$$

$$\mathbf{x}'\mathbf{A}\mathbf{x} = (x_1, x_2) \begin{pmatrix} 1 & -2 \\ -2 & 5 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = (x_1 - 2x_2, -2x_1 + 5x_2) \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = x_1^2 - 4x_1x_2 + 5x_2^2$$

- 행렬에는 여러 개의 숫자가 존재하기 때문에 스칼라와 달리 어떤 행렬이 0보다 크다 ( $>0$ ) 혹은 적다( $<0$ )라는 표현은 적합하지 않다. 그러나 행렬의 이차형식은 스칼라이므로 부호를 가질 수 있기 때문에 부호의 개념이 존재한다. 어떤 행렬의 이차형식이 항상 양일 때, 그 행렬을 “양정치 행렬(positive definite matrix)”라고 한다.

## 5. 대칭-양정치행렬의 고유값

- 행렬  $\mathbf{A} = \begin{pmatrix} 1 & 1 \\ -1 & 1 \end{pmatrix}$  이 양정치행렬 ?

Sol) 영이 아닌 임의의 벡터  $\mathbf{x}$  에 대하여,

$$\mathbf{x}'\mathbf{A}\mathbf{x} = \begin{pmatrix} x_1 & x_2 \end{pmatrix} \begin{pmatrix} 1 & 1 \\ -1 & 1 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = x_1^2 + x_2^2 > 0$$

가 항상 성립하므로 ( $\mathbf{x} \neq 0$ ), 행렬  $\mathbf{A}$  는 양정치행렬이다

- 행렬  $\mathbf{A}_{n \times n}$  에 대하여, 모든 고유값(eigenvalue)이  $\lambda_i > 0, \quad i = 1, 2, \dots, n$  이면 행렬  $\mathbf{A}$  는 양정치 행렬이다.

- 요약: 양정치행렬  $\mathbf{A}$  는:

- (1) 0 이 아닌 임의의 벡터  $\mathbf{x}$  에 대하여  $\mathbf{x}'\mathbf{A}\mathbf{x} > 0$  이 항상 성립한다.
- (2) 고유값이 모두 양수 ( $>0$ ) 이다.



## 8. 대칭-양정치행렬의 고유값

- 스칼라에 부호를 부여하듯이 행렬에도 부호를 부여할 수 있을까?

- 양의 정부호 행렬(positive definite matrix)  $\mathbf{A}$  if

양의 정부호 행렬 :  $\mathbf{0}$ 이 아닌 모든 벡터  $\mathbf{x}$ 에 대해,  $\mathbf{x}^T \mathbf{A} \mathbf{x} > 0$

- 예를 들어,  $\begin{pmatrix} 1 & 0 \\ 0 & 2 \end{pmatrix}$ 는  $(x_1 \ x_2) \begin{pmatrix} 1 & 0 \\ 0 & 2 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = x_1^2 + 2x_2^2$  이므로

$\begin{pmatrix} 1 & 0 \\ 0 & 2 \end{pmatrix}$ 는 양의 정부호 행렬

양의 정부호 행렬의 고유값은 모두 양수이다.

양의 준정부호 행렬의 고유값은 음수가 아니다. 즉 양수이거나 0이다.

양의 준정부호(positive semi-definite) 행렬:  $\mathbf{0}$ 이 아닌 모든 벡터  $\mathbf{x}$ 에 대해,  $\mathbf{x}^T \mathbf{A} \mathbf{x} \geq 0$

음의 정부호(negative definite) 행렬:  $\mathbf{0}$ 이 아닌 모든 벡터  $\mathbf{x}$ 에 대해,  $\mathbf{x}^T \mathbf{A} \mathbf{x} < 0$

음의 준정부호(negative semi-definite) 행렬:  $\mathbf{0}$ 이 아닌 모든 벡터  $\mathbf{x}$ 에 대해,  $\mathbf{x}^T \mathbf{A} \mathbf{x} \leq 0$

정부호(definite) 행렬이 아닌 부정부호(indefinite) 행렬: 벡터에 따라서 음수가 되기도 하고, 양수가 되기도 한다.  
부정부호 행렬의 고유값은 음수도 있고 양수도 있다.

정방행렬  $A_{n \times n}$  에 대하여

Inverse existing	Inverse not existing
$A^{-1}$ 이 존재한다.	$A^{-1}$ 이 존재하지 않는다.
full-rank 이다. $\text{rank}(A)=n$	full-rank 아니다. $\text{rank}(A)<n$
A는 정칙(non-singular)이다.	A는 비정칙(singular)이다.
$ A $ 는 0이 아니다.	$ A $ 는 0이다.
$Ax=0$ 의 해는 오로지 $x=0$ 만이다.	$Ax=0$ 의 해는 $x=0$ 이 아닌 $x$ 도 존재한다.
A는 $n$ 개의 선형독립인 열(행)벡터를 가진다.	A는 $n$ 개 보다 적은 개수의 선형독립인 열(행)벡터를 가진다.

▷ 정칙행렬(nonsingular matrix) (완전계수 행렬)

$A : n \times n$  행렬이고,  $\text{rank}(A)=n \Rightarrow A : \text{정칙행렬}$

## ■ 정리

**정리 2-1** 다음 성질은 서로 필요충분조건이다.

- $A$ 는 역행렬을 가진다. 즉, 특이행렬이 아니다.
- $A$ 는 최대계수를 가진다.
- $A$ 의 모든 행이 선형독립이다.
- $A$ 의 모든 열이 선형독립이다.
- $A$ 의 행렬식은 0이 아니다.
- $A^T A$ 는 양의 정부호 positive definite 대칭 행렬이다.
- $A$ 의 고윳값은 모두 0이 아니다.

---

역행렬이 없는 행렬: 특이행렬(singular matrix)

# 스펙트럼 분해

(spectral decomposition)  
(eigenvalue decomposition)

# 특이값 분해

(singular value decomposition, SVD)

## ■ 분해(decomposition)란?

- 정수 3717은 특성이 보이지 않지만,  $3 \times 3 \times 7 \times 59$ 로 소인수 분해를 하면 특성이 보이듯이, 행렬도 분해하면 여러모로 유용함

# 행렬의 분해

$$A = \sum_{i=1}^n \sigma_i u_i v_i^T = \begin{array}{|c} \hline \\ \hline \end{array} + \begin{array}{|c} \hline \\ \hline \end{array} + \dots$$

# 4.1 스펙트럼 분해(Spectral Decomposition)

- 여기서는 대칭행렬은 '스펙트럼 분해', 대칭이 아닌 일반행렬의 경우에는 '특이값 분해'를 통해 여러 개의 '행렬의 합'으로 표현 가능

## 4.1 스펙트럼 분해

- 한 개의 대칭행렬이 여러 개의 합으로 분해

### Theorem 4.1 (스펙트럼 분해)

행렬  $A_{n \times n}$ 이 대칭행렬이고, 고유값이  $|\lambda_1| \geq |\lambda_2| \geq \dots \geq |\lambda_n|$  일 때, 직교 정규벡터로 이루어진

행렬  $P = (\underline{v}_1, \underline{v}_2, \dots, \underline{v}_n)$  와 고유값으로 이루어진 대각행렬  $D = \begin{pmatrix} \lambda_1 & \dots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \dots & \lambda_n \end{pmatrix}$

에 대하여 행렬  $A$  는 다음과 같이 스펙트럼 분해된다.

$$A = PDP^T = \lambda_1 \underline{v}_1 \underline{v}_1^T + \lambda_2 \underline{v}_2 \underline{v}_2^T + \dots + \lambda_n \underline{v}_n \underline{v}_n^T = \sum_{i=1}^n \lambda_i \underline{v}_i \underline{v}_i^T$$

## 4.1 스펙트럼 분해

**Example :** 행렬  $\mathbf{A}$ 의 고유값이 5, -5, 2 이며 고유벡터가 아래와 같을 때,  
 $\mathbf{A}$  를 스펙트럼 분해하라.

$$\mathbf{A} = \begin{pmatrix} 2 & 0 & 0 \\ 0 & 4 & 3 \\ 0 & 3 & -4 \end{pmatrix}, \quad \underline{u}_1 = \begin{pmatrix} 0 \\ 3 \\ 1 \end{pmatrix}, \quad \underline{u}_2 = \begin{pmatrix} 0 \\ 1 \\ -3 \end{pmatrix}, \quad \underline{u}_3 = \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix}$$

**(SOL)** 위의 고유벡터는 서로 직교하되 길이가 1이 아니므로 정규화 시키면,

$$\underline{v}_1 = \begin{pmatrix} 0 \\ \frac{3}{\sqrt{10}} \\ \frac{1}{\sqrt{10}} \end{pmatrix}, \quad \underline{v}_2 = \begin{pmatrix} 0 \\ \frac{1}{\sqrt{10}} \\ -\frac{3}{\sqrt{10}} \end{pmatrix}, \quad \underline{v}_3 = \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix} \quad \text{가 된다.}$$

## 4.1 스펙트럼 분해

따라서  $\mathbf{A}$ 는 다음과 같이 스펙트럼 분해된다.

$$\mathbf{A} = \sum_{i=1}^n \lambda_i \underline{v}_i \underline{v}_i^T = 5 \begin{pmatrix} 0 \\ \frac{3}{\sqrt{10}} \\ \frac{1}{\sqrt{10}} \end{pmatrix} \left( 0 \frac{3}{\sqrt{10}} \frac{1}{\sqrt{10}} \right) + (-5) \begin{pmatrix} 0 \\ \frac{1}{\sqrt{10}} \\ -\frac{3}{\sqrt{10}} \end{pmatrix} \left( 0 \frac{1}{\sqrt{10}} - \frac{3}{\sqrt{10}} \right) + 2 \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix} (1 \ 0 \ 0)$$

즉,

$$\mathbf{A} = \begin{pmatrix} 2 & 0 & 0 \\ 0 & 4 & 3 \\ 0 & 3 & -4 \end{pmatrix} = \begin{pmatrix} 0 & 0 & 0 \\ 0 & 4.5 & 1.5 \\ 0 & 1.5 & 0.5 \end{pmatrix} + \begin{pmatrix} 0 & 0 & 0 \\ 0 & -0.5 & 1.5 \\ 0 & 1.5 & -4.5 \end{pmatrix} + \begin{pmatrix} 2 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix}$$



## 4.1 스펙트럼 분해

Example 2 :

◎ 예제 5.22 on p.178

$$A = \begin{pmatrix} 13 & -4 & 2 \\ -4 & 13 & -2 \\ 2 & -2 & 10 \end{pmatrix}, \quad |A - \lambda I| = 0 \quad \Rightarrow \quad \lambda_1 = 18, \quad \lambda_2 = 9, \quad \lambda_3 = 9$$

$$\Rightarrow \quad v_1 = \begin{pmatrix} \frac{2}{3} \\ -\frac{2}{3} \\ \frac{1}{3} \end{pmatrix}, \quad v_2 = \begin{pmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \\ 0 \end{pmatrix}, \quad v_3 = \begin{pmatrix} \frac{1}{\sqrt{18}} \\ -\frac{1}{\sqrt{18}} \\ -\frac{4}{\sqrt{18}} \end{pmatrix}$$

$$\Rightarrow D = \text{diag}(18, 9, 9), \quad V = (v_1, v_2, v_3)$$

# 정방행렬의 대각화:

## 고유값 분해(eigenvalue decomposition)

[고유값 분해 (eigenvalue decomposition)]

$$A = PDP^{-1} = PDP^T$$

$$= (\mathbf{v}_1 \ \mathbf{v}_2 \ \cdots \ \mathbf{v}_n) \begin{pmatrix} \lambda_1 & 0 & 0 & 0 \\ 0 & \lambda_2 & 0 & 0 \\ 0 & 0 & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_n \end{pmatrix} (\mathbf{v}_1 \ \mathbf{v}_2 \ \cdots \ \mathbf{v}_n)^{-1}$$

$A$ :  $n \times n$  정방행렬 (n by n square matrix)

$\lambda_i$ : 고유값 (eigenvalue)

$\mathbf{v}_i$ : 고유값  $\lambda_i$ 에 대응하는 고유벡터 (eigenvector)

$P$ : 고유벡터  $\mathbf{v}_i$ 로 이루어진 행렬

$D$ : 고유값  $\lambda_i$ 로 이루어진 대각행렬 (diagonal matrix)

행렬  $A$ 가 역행렬을 가질 조건: 0이 아닌 고유값들을 갖는다.

행렬  $A$ 가 대각화될 조건:  $n$ 개의 선형 독립인 고유벡터들을 갖는다.

# 행렬 분해: 고유값 분해 (eigenvalue decomposition)

## ■ 고유값 분해 eigenvalue decomposition

$$A = PDP^{-1}$$

- $P$  는  $A$ 의 고유 벡터를 열에 배치한 행렬이고  $D$ 는 고유값을 대각선에 배치한 대각행렬
- 예를 들어,  $\begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} = \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix} \begin{pmatrix} 3 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} 0.5 & 0.5 \\ 0.5 & -0.5 \end{pmatrix}$
- 고유값 분해는 정사각행렬에만 적용 가능한데, 기계 학습에서는 정사각행렬이 아닌 경우의 분해도 필요하므로 고유값 분해는 한계를 가짐

=> 특이값 분해

# 행렬 분해: 특이값 분해 (singular value decomposition, SVD)

■  $n*m$  행렬  $\mathbf{A}$ 의 특이값 분해 SVD(singular value decomposition)

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^T$$

- 왼쪽 특이행렬  $\mathbf{U}$ 는  $\mathbf{A}\mathbf{A}^T$ 의 고유 벡터를 열에 배치한  $n*n$  행렬
- 오른쪽 특이행렬  $\mathbf{V}$ 는  $\mathbf{A}^T\mathbf{A}$ 의 고유 벡터를 열에 배치한  $m*m$  행렬
- $\mathbf{D}$ 는  $\mathbf{A}\mathbf{A}^T$ 의 고유값의 제곱근을 대각선에 배치한  $n*m$  대각행렬

예를 들어,  $\mathbf{A}$ 를 4\*3 행렬이라고 했을 때 다음과 같이 특이값 분해가 된다.

$$\mathbf{A} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 2 & 2 \\ 3 & 1 & 0 \\ 1 & 0 & 2 \end{pmatrix} = \begin{pmatrix} -0.1914 & -0.2412 & 0.1195 & -0.9439 \\ -0.5144 & 0.6990 & -0.4781 & -0.1348 \\ -0.6946 & -0.6226 & -0.2390 & 0.2697 \\ -0.4651 & 0.2560 & 0.8367 & 0.1348 \end{pmatrix}$$
$$\begin{pmatrix} 3.7837 & 0 & 0 \\ 0 & 2.7719 & 0 \\ 0 & 0 & 1.4142 \\ 0 & 0 & 0 \end{pmatrix} \begin{pmatrix} -0.7242 & -0.4555 & -0.5177 \\ -0.6685 & 0.2797 & 0.6891 \\ 0.1690 & -0.8452 & 0.5071 \end{pmatrix}$$

## 4.2 특이값 분해

(Singular Value Decomposition , SVD)

- 대칭행렬이 아닌 일반적인  $n \times m$  행렬에서 적용 가능한 분해

- 행렬근사(matrix approximation)나 최소제곱(Least squares)기법에서 적용되는 매우 유용한 분해법이다.

### Theorem 4.2 (SVD)

행렬  $A_{n \times m}$ 에 대하여 ( $n \geq m = \text{Rank}(A)$ ), 다음과 같은 분해를 특이값 분해라고 한다.

$$A_{n \times m} = U_{n \times m} D_{m \times m} V_{m \times m}^T$$

여기에서 (1)  $U^T U = V^T V = I_m$

$$(2) A A^T \underline{u}_i = \lambda_i \underline{u}_i \quad , i = 1, 2, \dots, m$$

$$(3) A^T A \underline{v}_i = \lambda_i \underline{v}_i \quad , i = 1, 2, \dots, m$$

(4)  $D$ 는 아래와 같이 정의 된다. ( $\sqrt{\lambda_1} \geq \sqrt{\lambda_2} \geq \dots \geq \sqrt{\lambda_m} > 0$ )

$$D = \begin{pmatrix} \sqrt{\lambda_1} & \dots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \dots & \sqrt{\lambda_m} \end{pmatrix}$$

참고: 행렬  $A A^T$  (혹은  $A^T A$ ) 은 대칭행렬

## 4.2 특이값 분해

(Singular Value Decomposition , SVD)

**Proof :** 이를 확인하기 위해  $A = UDV^T$  라고 하면,

$$AA^T = UDV^TVDU^T = UD^2U^T = (\underline{u}_1, \underline{u}_2, \dots, \underline{u}_m) \begin{pmatrix} \lambda_1 & \dots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \dots & \lambda_m \end{pmatrix} (\underline{u}_1, \underline{u}_2, \dots, \underline{u}_m)^T$$

이것은 행렬  $AA^T$  의 스펙트럼 분해와 일치한다. 따라서  $\lambda_i$  는  $AA^T$ 의 고유값이고  $\underline{u}_i$ 는 직교하는 고유벡터이다. 마찬가지로

$$A^TA = VDU^TUDV^T = VD^2V^T = (\underline{v}_1, \underline{v}_2, \dots, \underline{v}_m) \begin{pmatrix} \lambda_1 & \dots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \dots & \lambda_m \end{pmatrix} (\underline{v}_1, \underline{v}_2, \dots, \underline{v}_m)^T$$

가 되어  $\lambda_i$  는  $A^TA$ 의 고유값이고  $\underline{v}_i$ 는 직교하는 고유벡터이다.

참고: 행렬  $AA^T$  (혹은  $A^TA$ ) 은 대칭행렬

## 4.2 특이값 분해

(Singular Value Decomposition , SVD)

**Remark :** 만일  $\lambda_i$  가 행렬  $\mathbf{A}^T \mathbf{A}$  (혹은  $\mathbf{A} \mathbf{A}^T$ )의 고유값이면,  $\sqrt{\lambda_i}$  는 행렬  $\mathbf{A}$ 의 특이값(singular value)이다.

**Remark :** 행렬  $U$ 의 열벡터  $\underline{u}_i$ 를 '왼쪽 특이 벡터(left singular vector)' , 행렬  $V$ 의 열벡터  $\underline{v}_i$ 를 '오른쪽 특이벡터(right singular vector)' 라고 한다.

**Remark :** Theorem 4.2 에서  $\text{Rank}(A) = n \leq m$  인 경우에는 다음과 같이 된다.

$$A_{n \times m} = U_{n \times n} D_{n \times n} (V_{m \times n})^T$$

## 4.2 특이값 분해

(Singular Value Decomposition , SVD)

**Example1** 행렬  $\mathbf{A}$  를 특이값 분해(SVD)를 실시하여라.

$$\mathbf{A} = \begin{pmatrix} 2 & 0 & -1 \\ 0 & 1 & 0 \end{pmatrix}$$

**(SOL)** 행렬  $\mathbf{A}\mathbf{A}^T$  의 고유값과 고유벡터를 구하면,

$$\mathbf{A}\mathbf{A}^T = \begin{pmatrix} 2 & 0 & -1 \\ 0 & 1 & 0 \end{pmatrix} \begin{pmatrix} 2 & 0 \\ 0 & 1 \\ -1 & 0 \end{pmatrix} = \begin{pmatrix} 5 & 0 \\ 0 & 1 \end{pmatrix}$$

그러므로  $\lambda_1 = 5$  ,  $\lambda_2 = 1$  이 고유값이 되며 고유벡터를 구하면,

$$\underline{u}_1 = \begin{pmatrix} 1 \\ 0 \end{pmatrix} \quad , \quad \underline{u}_2 = \begin{pmatrix} 0 \\ 1 \end{pmatrix} \quad \text{가 되어} \quad U = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \text{이다.}$$

한편  $\mathbf{A}^T\mathbf{A}$ 의 고유값과 고유벡터를 구하면,

$$\mathbf{A}^T\mathbf{A} = \begin{pmatrix} 2 & 0 \\ 0 & 1 \\ -1 & 0 \end{pmatrix} \begin{pmatrix} 2 & 0 & -1 \\ 0 & 1 & 0 \end{pmatrix} = \begin{pmatrix} 4 & 0 & -2 \\ 0 & 1 & 0 \\ -2 & 0 & 1 \end{pmatrix} \quad \text{에서}$$



## 4.2 특이값 분해

고유값은 5, 1, 0 이 된다. 이제 0 이 아닌 고유값은  $AA^T$  때와 마찬가지로 5, 1 이 되고  
직교 정규 벡터는

$$\underline{v}_1 = \begin{pmatrix} \frac{2}{\sqrt{5}} \\ 0 \\ 1 \\ -\frac{1}{\sqrt{5}} \end{pmatrix}, \quad \underline{v}_2 = \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix} \quad \text{가 되어} \quad V = \begin{pmatrix} \frac{2}{\sqrt{5}} & 0 \\ 0 & 1 \\ -\frac{1}{\sqrt{5}} & 0 \end{pmatrix} \quad \text{이다.}$$

따라서 특이값 분해(SVD)는 다음과 같이 된다.

$$\mathbf{A} = \begin{pmatrix} 2 & 0 & -1 \\ 0 & 1 & 0 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} \sqrt{5} & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} \frac{2}{\sqrt{5}} & 0 & -\frac{1}{\sqrt{5}} \\ 0 & 1 & 0 \end{pmatrix} = UDV^T$$

### Proposition 4.1 (SVD의 전개)

행렬  $A_{n \times m}$ 에 대하여 ( $\text{Rank}(A) = n \leq m$ ) , 특이값 분해를 하면 행렬  $A$  는 다음과 같이  $n$ 개의  $n \times m$  행렬의 합으로 표현 가능하다.

$$A_{n \times m} = U_{n \times n} D_{n \times n} (V_{m \times n})^T = \sum_{i=1}^n \sqrt{\lambda_i} \underline{u}_i \underline{v}_i^T$$

## 4.2 특이값 분해

**Example1** : 앞의 Proposition 4.1을 이용하여

$$\begin{aligned} \mathbf{A} &= \begin{pmatrix} 2 & 0 & -1 \\ 0 & 1 & 0 \end{pmatrix} = U_{2 \times 2} D_{2 \times 2} (V_{3 \times 2})^T = \sum_{i=1}^2 \sqrt{\lambda_i} \underline{u}_i \underline{v}_i^T \\ &= \sqrt{5} \times \begin{pmatrix} 1 \\ 0 \end{pmatrix} \left( \frac{2}{\sqrt{5}} \quad 0 \quad -\frac{1}{\sqrt{5}} \right) + 1 \times \begin{pmatrix} 0 \\ 1 \end{pmatrix} (0 \quad 1 \quad 0) \\ &= \begin{pmatrix} 2 & 0 & -1 \\ 0 & 0 & 0 \end{pmatrix} + \begin{pmatrix} 0 & 0 & 0 \\ 0 & 1 & 0 \end{pmatrix} \quad \text{가 된다.} \end{aligned}$$

**Remark :**

행렬  $A_{n \times m}$ 에 대하여 ( $n \geq m = \text{Rank}(A)$ ) , 특이값 분해를 하면 행렬  $A$  는 다음과 같이  $m$ 개의  $n \times m$  행렬의 합으로 표현 가능하다.

$$A_{n \times m} = U_{n \times m} D_{m \times m} V_{m \times m}^T = \sum_{i=1}^m \sqrt{\lambda_i} \underline{u}_i \underline{v}_i^T$$

# 특이값 분해(singular value decomposition)

Example 2 : [1] 먼저  $A \times t(A)$  의 고유벡터인  $U$ 를 구해보자

특이값 분해 예제 (example of SVD)

$$A = \begin{pmatrix} 3 & 6 \\ 2 & 3 \\ 0 & 0 \\ 0 & 0 \end{pmatrix} \quad \text{라고 했을 때,}$$

$$\Rightarrow AA^T = \begin{pmatrix} 3 & 6 \\ 2 & 3 \\ 0 & 0 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} 3 & 2 & 0 & 0 \\ 6 & 3 & 0 & 0 \end{pmatrix} = \begin{pmatrix} 45 & 24 & 0 & 0 \\ 24 & 13 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix} = W \quad \text{라고 하면,}$$

$$Wx = \lambda x \quad \text{에서} \quad (W - \lambda I)x = 0$$

$$(W - \lambda I)x = \begin{pmatrix} 45 - \lambda & 24 & 0 & 0 \\ 24 & 13 - \lambda & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix} = 0$$

# 특이값 분해(singular value decomposition)

## Example 2 :

위의 특성방정식(characteristic equations)을 풀면 (by using R),

$AA^T=W$ 의 고유값(eigenvalue)  $\lambda_i$  :  $\lambda_1=57.844$ ,  $\lambda_2=0.155$ ,  $\lambda_3=0$ ,  $\lambda_4=0$

고유값 (eigenvalue)  $\lambda_i$ 에 대응하는  
고유벡터(eigenvectors)  $x_i$  :

$$\begin{array}{cccc} \downarrow & \downarrow & \downarrow & \downarrow \\ x_1^T = \begin{pmatrix} 0.881 \\ 0.471 \\ 0 \\ 0 \end{pmatrix} & x_2^T = \begin{pmatrix} -0.471 \\ 0.881 \\ 0 \\ 0 \end{pmatrix} & x_3^T = \begin{pmatrix} 0 \\ 0 \\ 0 \\ 1 \end{pmatrix} & x_4^T = \begin{pmatrix} 0 \\ 0 \\ 1 \\ 0 \end{pmatrix} \end{array}$$

$$\therefore U = \text{eigenvectors of } AA^T = \begin{pmatrix} 0.881 & -0.471 & 0 & 0 \\ 0.471 & 0.881 & 0 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 1 & 0 \end{pmatrix}$$

# 특이값 분해(singular value decomposition)

## Example 2 :

[2] 다음으로,  $t(A) \times A$  의 고유벡터(eigenvectors)를 구해보겠습니다. 위의 (1)번 풀이 과정과 동일합니다.

$$A^T A = \begin{pmatrix} 3 & 2 & 0 & 0 \\ 6 & 3 & 0 & 0 \end{pmatrix} \begin{pmatrix} 3 & 6 \\ 2 & 3 \\ 0 & 0 \\ 0 & 0 \end{pmatrix} = \begin{pmatrix} 13 & 24 \\ 24 & 45 \end{pmatrix} = W_2 \quad \text{라고 하면,}$$

$$W_2 x = \lambda x \quad \text{에서} \quad (W_2 - \lambda I)x = 0$$

$$(W_2 - \lambda I)x = \begin{pmatrix} 13 - \lambda & 24 \\ 24 & 45 - \lambda \end{pmatrix} = 0$$

# 특이값 분해(singular value decomposition)

## Example 2 :

위의 특성방정식(characteristic equations)을 풀면 (by using R),

$A^T A = W_2$ 의 고유값(eigenvalue)  $\lambda_i$  :  $\lambda_1 = 57.844$ ,  $\lambda_2 = 0.155$

고유값 (eigenvalue)  $\lambda_i$ 에 대응하는  
고유벡터(eigenvectors)  $x_i$  :

$$\begin{array}{ccc} \downarrow & & \downarrow \\ x_1^T = \begin{pmatrix} 0.471 \\ 0.881 \end{pmatrix} & & x_2^T = \begin{pmatrix} -0.881 \\ 0.471 \end{pmatrix} \end{array}$$

$$\therefore V^T = \text{eigenvectors of } A^T A = \begin{pmatrix} 0.471 & -0.881 \\ -0.881 & 0.471 \end{pmatrix}$$

# 특이값 분해(singular value decomposition)

## Example 2 :

[3] 다음으로,  $A \times t(A)$ ,  $t(A) \times A$  의 고유값(eigenvalue)의 제곱근(square root)을 특이값(singular value) 대각원소로 가지고 나머지는 '0'인 대각행렬  $\Sigma$  를 구해보겠습니다.

$AA^T=W$ 의 고유값(eigenvalue)  $\lambda_i$ :  $\lambda_1=57.844$ ,  $\lambda_2=0.155$ ,  $\lambda_3=0$ ,  $\lambda_4=0$

특이값(singular value)  $\sigma_i$ :  $\sigma_1 = \sqrt{\lambda_1} = \sqrt{57.844} = 7.605$

$\sigma_2 = \sqrt{\lambda_2} = \sqrt{0.155} = 0.394$

$$\therefore \Sigma = \begin{pmatrix} 7.605 & 0 \\ 0 & 0.394 \\ 0 & 0 \\ 0 & 0 \end{pmatrix} \quad (\sigma_1 \geq \sigma_2 \geq 0)$$

# 특이값 분해(singular value decomposition)

[4] 위에서 구한  $U$ ,  $V^T$ ,  $\Sigma$  를 종합하면 끝이네요.

Example 2 :

$$A = \begin{pmatrix} 3 & 6 \\ 2 & 3 \\ 0 & 0 \\ 0 & 0 \end{pmatrix} \text{ 일 때,}$$

$A$ 의 특이값 분해 (Singular Value Decomposition)은

$$A = U \Sigma V^T = \begin{pmatrix} 0.881 & -0.471 & 0 & 0 \\ 0.471 & 0.881 & 0 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 1 & 0 \end{pmatrix} \begin{pmatrix} 7.605 & 0 \\ 0 & 0.394 \\ 0 & 0 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} 0.471 & -0.881 \\ 0.881 & 0.471 \end{pmatrix}$$

$U$



$AA^T$ 의 고유벡터  
(eigenvectors of  $AA^T$ )

$\Sigma$



$\sigma_i = \sqrt{\lambda_i}$   
( $\lambda_1 \geq \lambda_2 \geq \dots \geq 0$ 이며,  
대각원 소이 외 모두 0)

$V^T$



$A^T A$ 의 고유벡터  
(eigenvectors of  $A^T A$ )



# 특이값 분해(singular value decomposition)


$$A = U\Sigma V^T$$

$A$ :  $m \times n$  직사각행렬(m by n rectangular matrix)

$U$ :  $A$ 의 left singular vector로 이루어진  $m \times m$  직교행렬(orthogonal matrix)

$\Sigma$ : 주대각성분이  $\sqrt{\lambda_i}$ 로 이루어진  $m \times n$  직사각대각행렬(diagonal matrix)

$V$ :  $A$ 의 right singular vector로 이루어진  $n \times n$  직교행렬(orthogonal matrix)



## 4.3 특이값 분해의 활용

### 4.3 특이값 분해(SVD)의 활용

- SVD를 이용하여 여러 개의 행렬의 합으로 표현가능.

(1) 역행렬이 존재하지 않는 경우의 일반화역행렬(generalized inverse)계산

(2) 행렬의 계수(Rank) 계산(0 이 아닌 특이값의 개수 = 행렬의 계수)

(3) 행렬의 근사(matrix approximation)

(4) 영상 이미지 압축

## 4.3 특이값 분해의 활용

### 행렬의 근사

행렬  $A_{n \times m}$ 에 대하여 ( $\text{Rank}(A) = n \leq m$ ) , 특이값 분해를 하면 행렬  $A$  는 다음과 같이  $n$ 개로 분해된  $n \times m$  행렬의 합으로 표현 가능하다. ( $\sqrt{\lambda_1} \geq \sqrt{\lambda_2} \geq \dots \geq \sqrt{\lambda_m}$ )

$$\begin{aligned} A_{n \times m} &= U_{n \times n} D_{n \times n} (V_{m \times n})^T \\ &= \sum_{i=1}^n \sqrt{\lambda_i} \underline{u}_i \underline{v}_i^T = \sqrt{\lambda_1} \underline{u}_1 \underline{v}_1^T + \sqrt{\lambda_2} \underline{u}_2 \underline{v}_2^T + \dots + \sqrt{\lambda_k} \underline{u}_k \underline{v}_k^T + \sqrt{\lambda_{k+1}} \underline{u}_{k+1} \underline{v}_{k+1}^T + \dots + \sqrt{\lambda_n} \underline{u}_n \underline{v}_n^T \end{aligned}$$

여기서 어떤  $k(< n)$  시점 이후의 특이값이 충분히 작다면,

$$\text{즉, } \sqrt{\lambda_{k+1}}, \sqrt{\lambda_{k+2}}, \dots, \sqrt{\lambda_n} \approx 0,$$

$$\mathbf{A} \approx \sqrt{\lambda_1} \underline{u}_1 \underline{v}_1^T + \sqrt{\lambda_2} \underline{u}_2 \underline{v}_2^T + \dots + \sqrt{\lambda_k} \underline{u}_k \underline{v}_k^T$$


행렬  $\mathbf{A}$  는  $k(< n)$ 개의 행렬만으로도 충분히 근사 시킬 수 있을 것이다.

## 4.3 특이값 분해의 활용


Original (Rank 200)




Rank 1




Rank 2



Rank 3



Rank 5



Rank 10



Rank 15



Rank 25



Rank 50



## 4.3 특이값 분해의 활용

이와 같이 전체  $m$ 개로 이루어진 분해 중에서 일부분( $k$ 개)을 이용해 행렬을 근사 시키는 방법을 'k-계수근사(k-rank approximation)' 이라고 하며, 아래는 행렬  $\mathbf{A}$ 의 2-계수 근사를 보여준다.


$$\mathbf{A} \approx \sqrt{\lambda_1} \underline{u}_1 \underline{v}_1^T + \sqrt{\lambda_2} \underline{u}_2 \underline{v}_2^T$$

이와 같이 행렬의 근사는 사이즈가 크고 복잡한 행렬을 간단한 몇 개의 벡터로 이루어진 행렬로 표현가능 하다는 의미.

⇒ 데이터 마이닝 , microarray 발현분석 같은 유전자 분석에 많이 사용.

부록

서로 같은 벡터라 함은 '크기'와 '방향'이 둘다 같은 벡터임을 의미합니다.



벡터  $\vec{a}$ (AB)와 벡터  $\vec{b}$ (CD)가 서로 같은 벡터는 당연히 관계를

$$\vec{a} = \vec{b}, AB = CD$$


라고 나타내겠죠?

출처:


<http://blog.naver.com/PostView.nhn?blogId=ao9364&logNo=220740519031&categoryNo=9&parentCategoryNo=9&viewDate=&currentPage=1&postListTopCurrentPage=1&from=postView>

## <벡터의 덧셈>

아주 쉽습니다.



먼저 덧셈부터 해 볼게요. 벡터의 덧셈은 '시점과 종점' 만 잘 찾아내면 됩니다. 크게 두가지 방법이 있는데, 첫번째 방법은 삼각형 법 입니다.



한 벡터의 종점을 다른 벡터의 시점에 당도록 평행이동 시킨 뒤, 당지 않은 두 시점과 종점을 연결하면 됩니다.

결국 시점과 종점을 이으면 된다는 사실이죠!

출처:

<http://blog.naver.com/PostView.nhn?blogId=ao9364&logNo=220740519031&categoryNo=9&parentCategoryNo=9&viewDate=&currentPage=1&postListTopCurrentPage=1&from=postView>




## <벡터의 뺄셈>

가장 쉽게 생각하시는 방법은,

$$\vec{a} - \vec{b} = \vec{a} + (-\vec{b})$$

빼려는 벡터의 역벡터를 '더해준다' 라고 생각하시면 됩니다. 다른 방법으로는 뒤 벡터의 종점에서 앞 벡터의 종점으로 가는 벡터이다... 라는 설명도 있는데, 저는 개인적으로 헛갈릴 때에는 역벡터를 더하는 방법이 제일 간단하더라고요.

예를 들어보도록 하죠.




요렇게 방향만 바꿔서 더해주시면 된답니다~~

출처:

<http://blog.naver.com/PostView.nhn?blogId=ao9364&logNo=220740519031&categoryNo=9&parentCategoryNo=9&viewDate=&currentPage=1&postListTopCurrentPage=1&from=postView>


### 벡터의 덧셈



$$\vec{a} = (a_1, a_2) \quad \vec{b} = (b_1, b_2)$$


$$\vec{a} + \vec{b} = \vec{c} = (a_1 + b_1, a_2 + b_2) = (c_1, c_2)$$

### 벡터의 뺄셈



$$\vec{a} = (a_1, a_2) \quad \vec{b} = (b_1, b_2)$$

$$\vec{a} - \vec{b} = \vec{c} = (a_1 - b_1, a_2 - b_2) = (c_1, c_2)$$



사실 어떻게 정의하든 상관없지만 일반적인 내적의 정의는 다음과 같아요.

$$a \cdot b = |a| |b| \cos \theta$$


단 여기서  $\theta$ 는 a라는 벡터와 b라는 벡터가 이루고 있는 0과 180도 사이의 각입니다.

$|a|$


는 a 벡터의 크기를 의미하고

$|b|$

는 b 벡터의 크기를 의미합니다.



가령



가령 위와 같은 두개의 벡터가 있다고 해봐요.

u의 크기는 3, v의 크기는 5라고 가정해봅시다.

그럼

u와 v의 내적은 얼마일까요?

정의대로 하면 되지요.

$$|u| = 3$$

$$|v| = 5$$

$$\theta = 20^\circ$$


이 되니까 내적은

u와 v의 내적 =

$$|u| \times |v| \times \cos \theta = 3 \times 5 \times \cos 20^\circ$$


출처: <http://tip.daum.net/question/54855462>

일단 내적은 그냥 **정의**로 받아들이시기 바랍니다.  
그냥 연습삼아 문제를 몇개 풀어보죠.



이 문제의 내적은 얼마일까요?

답:  $1 \times 1.2 \times \cos(90^\circ) = 0$



이 문제의 내적은 얼마일까요?

답 :

$$1 \times 1 \times \cos 45^\circ = \frac{\sqrt{2}}{2}$$

원래 내적의 정의는

$$u \cdot v = |u| |v| \cos \theta$$

이지만

만약  $u$ 와  $v$ 를 좌표계로

$$u = (u_1, u_2)$$

$$v = (v_1, v_2)$$

로 나타낼 수 있다면

그냥 간단하게

$$u \cdot v = u_1 v_1 + u_2 v_2$$

로 해도 결과가 똑같다는 말이죠.

이것은 다시 말해서

$$u \cdot v = |u| |v| \cos \theta = u_1 v_1 + u_2 v_2$$

$$\longrightarrow \cos \theta = \frac{u_1 v_1 + u_2 v_2}{|u| |v|}$$

출처: <http://tip.daum.net/question/54855462>